

# Rendu\_Notebook\_Oiseaux

Groupe Oiseaux

2024-05-05

## I. Import des données et variables de travail

Avant de pouvoir faire quelque analyse que ce soit, il est important que nos données soient propres et que nous ayons toutes les mesures nécessaires à disposition. Dans cette première partie, nous nous occuperons donc d'importer nos données, de les nettoyer, de préparer ce dont nous aurons besoin plus tard mais aussi de calculer de nouvelles variables synthétiques pour nos futures analyses statistiques.

### A. Construction du tableau de données

Tout d'abord, nous importons nos données brutes et celles de l'année dernière. Nous les stockons dans un même tableau tout en notant dans une nouvelle colonne à quel jeu de données appartient chaque ligne.

```
data_2024 <- read_csv(
  here("data", "table_birds_2024.csv"),
  col_names = TRUE,
  col_types = "Dtffffffffffiiiiididdi",
  col_select = c(-23)
) |> na.omit()

data_2023 <- read_csv(
  "data/table_birds_2023.csv",
  col_names=TRUE,
  col_types = "ftffffffffffiiiiididdi",
  col_select = c(-23)
) |> na.omit()

data <- data_2024 |>
  mutate(JOUR=factor(JOUR, labels = as.character(seq(1,4))),
         ANNEE = "2024", .before=1) |>
  bind_rows(mutate(data_2023, ANNEE = "2023"))
```

Ensuite, nous homogénéisons les données que nous avons à disposition.

Premièrement, nous voulons que les valeurs correspondant à `LATENCE` et `DISTANCE_MIN` infinie soient les mêmes quelque soit l'origine des données. Ici, en 2023, les étudiants avaient choisi respectivement 180s pour la première variable et 50m pour la seconde et nous avons choisi 10000s et 10000m. Le problème est que nous ne comptons pas la latence jusqu'à 180s mais 90s et que nous faisons la distinction entre les oiseaux qui ne s'étaient pas montrés (`LATENCE` et `DISTANCE_MIN` à 10000) et ceux que nous entendions de loin (`DISTANCE_MIN` à 50m). Nous avons alors décidé de considérer comme infinies les valeurs de `LATENCE` supérieures à 90s et que les `DISTANCE_MIN` correspondantes soient également infinies. Bien que très criticable, cela nous semble la meilleure option afin que les jeux de données soient le plus comparables possible. Les valeurs infinies de `LATENCE` seront fixées à 180s et celles de `DISTANCE_MIN` à 75m. Nous fixerons alors le seuil de `LATENCE` à 180s et de `DISTANCE_MIN` à 100m.

```
data <- data |> mutate(
  LATENCE = ifelse(LATENCE>90, 180, LATENCE),
  DISTANCE_MIN = ifelse(DISTANCE_MIN==50 & LATENCE==180, 75,
    DISTANCE_MIN),
  DISTANCE_MIN = ifelse(DISTANCE_MIN > 50, 75, DISTANCE_MIN)
)
```

Il reste encore deux lignes “abhérentes” dans notre tableau et elles viennent de 2024 : alors que la `DISTANCE_MIN` est infinie, c’est à dire (normalement) que nous ne savons pas où est l’oiseau, la `LATENCE` n’est pas infinie... Nous préférons “corriger” la `LATENCE` et la mettre à 180s.

```
data <- data |> mutate(LATENCE = ifelse(DISTANCE_MIN==75, 180, LATENCE))
```

Nous allons maintenant introduire de nouvelles colonnes qui serviront à nos analyses.

D’abord, nous définissons `LATENCE_BINAIRE` comme la présence ou l’absence de réponse de l’oiseau étudié.

```
data <- data |> mutate(LATENCE_BINAIRE=ifelse(LATENCE==180,0,1), .before=c(13))
```

Ensuite, nous créons une colonne `MATIN_APREM` qui nous permettra de séparer les jours en deux : avant la pause du repas et après la pause du repas. A 12 : 30, nous étions toujours sur cette pause, donc nous choisissons cet horaire pour dichotomiser les journées.

```
data <- data |> mutate(
  MATIN_APREM=factor(ifelse(HEURE < hms("12:30:00"), 0, 1),
    labels=c("Matin", "Aprem")), .after=c(3)
)
```

On calcule également une nouvelle colonne telle que `CHANT_REPONSE = STROPHES_APRES - STROPHES_AVANT*2`. Cela permettra de tester la réponse en terme de chant des fauvettes à tête noire.

```
data <- data |> mutate(
  CHANT_REPONSE = STROPHES_APRES - STROPHES_AVANT*2, .after=c(16)
)
```

On ordonne ensuite les variables `factor` qui s’y prêtent.

```
data$ID_MALE <- factor(
  data$ID_MALE,
  levels = 1:11,
  ordered = TRUE
)

# Pour les tests et que les graphiques soient propres
data$DIFFUSION <- factor(
  data$DIFFUSION,
  levels = c("FT_comp", "FT_sif", "FT_gaz", "FJ", "FG", "MC"),
  ordered = TRUE
)
```

Nous créons aussi une variable `DISTANCE_MIN_FACTOR` car nous avons mesuré la variable `DISTANCE_MIN` comme une variable qualitative ordinaire et non pas comme une variable quantitative.

```
data$DISTANCE_MIN_FACTOR <- factor(
  data$DISTANCE_MIN,
  labels=c("0", "< 2", "< 5", "< 10", "< 15", "< 20", "< 50", "Infini"),
  ordered = TRUE
)
```

Comme on a la colonne `ANNEE`, on peut simplifier `JOUR` et faire en sorte qu'elle indique le jour de la semaine (entre 1 et 4).

```
data <- data |> mutate(JOUR=factor(JOUR,labels=rep(1:4,2)))
```

Maintenant, nous allons garder quelques sous-tableaux de `data` car nous allons les utiliser régulièrement dans nos analyses.

Tout d'abord, nous mettons `data_2023` et `data_2024` à jour.

```
data_2023 <- data |> filter(ANNEE == 2023)
data_2024 <- data |> filter(ANNEE == 2024)
```

Ensuite, nous prenons un tableau contenant les lignes où les oiseaux ont répondu à la diffusion et un autre où ils n'ont pas répondu.

```
data_reponse <- data |> filter(LATENCE < 180)
data_nreponse <- data |> filter(LATENCE==180)
```


A présent, nous pouvons utiliser proprement nos données.

## B. Analyses en composante principale

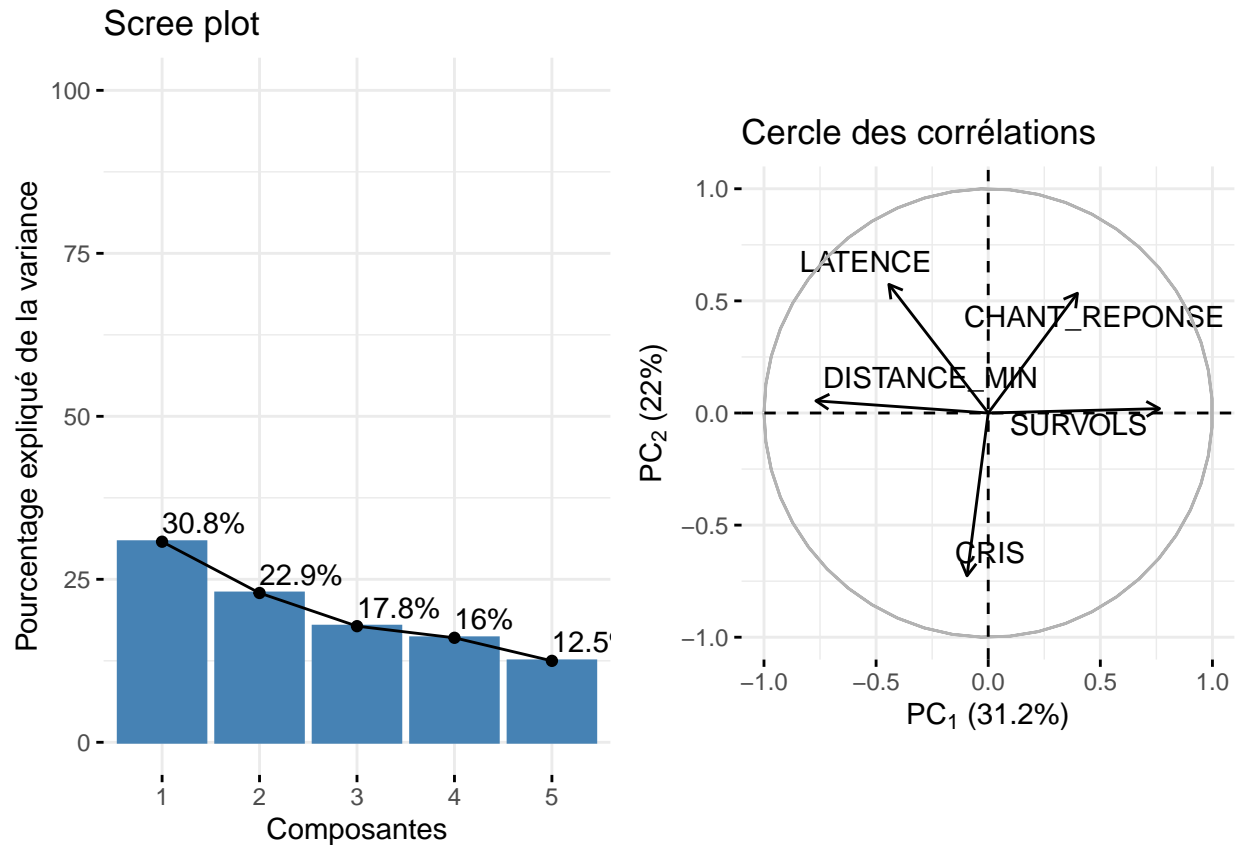
Afin d'étudier des effets probablement influencés par plusieurs de nos variables, nous allons chercher à construire de nouvelles grandeurs synthétiques que nous pourrions utiliser dans nos analyses statistiques. Pour cela, nous allons réaliser deux analyses en composante principale (ACP), la première sur les variables impliquées dans la réponses des fauvettes à tête noire lors de nos expériences et la seconde sur les variables environnementales susceptibles d'avoir un impact sur l'activité et donc la réactivité des oiseaux.

**1. Variables de réponse** Cette première ACP aura pour but la définition d'une variable `REPONSE_GLOBALE` décrite ci-dessus. Pour réaliser cette ACP, nous avons choisi les variables continues impliquées dans la réponse des oiseaux, c'est à dire cinq des variables disponibles dans notre tableau : `DISTANCE_MIN`, `LATENCE`, `CHANT_REPONSE`, `CRIS` et `SURVOLS`.

Tout d'abord, calculons l'ACP et stockons la dans une variable.




Ici, la  $PC_1$  semble expliquer une grande partie de la variance de nos données et pourrait alors sembler être une bonne approximation de la réactivité des oiseaux. Seulement, nous pouvons aussi remarquer que les variables **LATENCE** et **DISTANCE\_MIN** sont très corrélées entre elles et à la  $PC_1$ . Ainsi, cela pourrait être simplement dû à la forte influence des valeurs “infinies” dont nous parlions plus haut. Pour vérifier cela, nous allons de nouveau effectuer une ACP avec les 5 mêmes variables, mais cette fois-ci sur les oiseaux qui répondaient aux diffusions (**LATENCE\_BINAIRE == 1**).



Cette fois-ci, les corrélations sont moins fortes entre les variables et la composante principale, mais notre ACP est maintenant mauvaise car la  $PC_1$  n'explique plus que 31.2% de la variance des données. Si chacune des composante expliquait la même part de variance, alors chacune serait associée à 20%, soit à peine moins que 31.2%.

Nous n'utiliserons donc pas de variable de réponse globale pour étudier le comportement des oiseaux étudiés.

**2. Variables environnementales** Nous avons ensuite essayé de synthétiser les variables météorologiques et autres facteurs environnementaux en réalisant une ACP sur les colonnes **ENSOLEILLEMENT**, **TEMPERATURE**, **VENT\_MAX**, **VENT\_MOY** et **PUBLIC**. Nous n'avons pas gardé la variable **PLUIE** car elle est seulement intervenu lors de notre premier jour de terrain et qu'elle n'avait aucun poids dans les 2 premières composantes de l'ACP.



On voit ici qu'une part importante de la variance est expliquée par la  $PC_1$ , mais cette dernière n'est pas facilement interprétable comme nous pouvons le constater sur le cercle des corrélations. Bien que certaines de nos variables sont positivement corrélées avec la  $PC_1$  (CRIS, SURVOLS...), nous avons préféré ne pas l'utiliser car nous ne pouvions pas faire d'interprétation précise de ces résultats.

## II. Diffusion

Dans cette partie, nous allons chercher à répondre à notre problématique principale, à savoir :

**Quel est l'impact de différents chants d'oiseaux sur le comportement territorial des mâles de fauvette à tête noire ?**

Tout d'abord, nous créons un nouveau tableau avec une colonne STROPHES correspondant aux colonnes STROPHES\_AVANT et STROPHES\_APRES de data\_reponse l'une sur l'autre, contenant également une colonne désignant à quelle colonne appartenait la ligne de STROPHES. Il nous permettra de faire des plots avec comme facteur le moment de comptage des strophes (avant ou après) et de faire des tests appariés sur cette variable. La colonne ROW que nous rajoutons sert à identifier le numéro de ligne original (dans data\_reponse) afin de pouvoir faire les tests appariés.

```
data_reponse_long <- data_reponse |>
  mutate(
    STROPHES_AVANT=STROPHES_AVANT*2,
    ROW = as.factor(row_number())
  ) |>
  gather(
    key = "AVANT_APRES", value = "STROPHES",
    STROPHES_AVANT, STROPHES_APRES
  ) |>
```

```
convert_as_factor(AVANT_APRES) |>
mutate(AVANT_APRES=fct_rev(AVANT_APRES))
```

## A. Etude de la réaction “binaire”

Pour commencer nos analyse, nous utiliserons tout d’abord la variable LATENCE\_BINAIRE pour étudier la présence ou absence de réponse selon la diffusion passée. Nous utilisons une loi de Bernoulli pour modéliser la variable LATENCE\_BINAIRE car elle possède 2 issues chacune observée avec une probabilité donnée.

```
test_latbin_diffusion <- glm(
  LATENCE_BINAIRE ~ DIFFUSION, family="binomial",
  data = data
)
```

```
test_latbin_diffusion |> estimate_contrasts(p_adjust = "fdr") |>
add_significance()
```

```
## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.
```

```
## Marginal Contrasts Analysis
```

```
##
```

## Level1	## Level2	## Difference	## 95% CI	## SE	## df	## z	## p	## p.signif
## FG	## MC	## 0.05	## [-1.03, 1.13]	## 0.37	## Inf	## 0.14	## 0.886	## ns
## FJ	## FG	## 0.71	## [-0.36, 1.77]	## 0.36	## Inf	## 1.95	## 0.125	## ns
## FJ	## MC	## 0.76	## [-0.32, 1.84]	## 0.37	## Inf	## 2.06	## 0.117	## ns
## FT_comp	## FG	## 0.76	## [-0.30, 1.81]	## 0.36	## Inf	## 2.11	## 0.117	## ns
## FT_comp	## FJ	## 0.05	## [-1.00, 1.11]	## 0.36	## Inf	## 0.15	## 0.886	## ns
## FT_comp	## FT_gaz	## 0.12	## [-0.94, 1.17]	## 0.36	## Inf	## 0.33	## 0.886	## ns
## FT_comp	## FT_sif	## -0.36	## [-1.45, 0.73]	## 0.37	## Inf	## -0.97	## 0.452	## ns
## FT_comp	## MC	## 0.81	## [-0.26, 1.88]	## 0.37	## Inf	## 2.22	## 0.117	## ns
## FT_gaz	## FG	## 0.64	## [-0.42, 1.70]	## 0.36	## Inf	## 1.77	## 0.143	## ns
## FT_gaz	## FJ	## -0.07	## [-1.12, 0.99]	## 0.36	## Inf	## -0.18	## 0.886	## ns
## FT_gaz	## MC	## 0.69	## [-0.38, 1.77]	## 0.37	## Inf	## 1.89	## 0.125	## ns
## FT_sif	## FG	## 1.12	## [ 0.02, 2.21]	## 0.37	## Inf	## 3.00	## 0.020	## *
## FT_sif	## FJ	## 0.41	## [-0.68, 1.51]	## 0.37	## Inf	## 1.11	## 0.402	## ns
## FT_sif	## FT_gaz	## 0.48	## [-0.61, 1.57]	## 0.37	## Inf	## 1.29	## 0.331	## ns
## FT_sif	## MC	## 1.17	## [ 0.06, 2.28]	## 0.38	## Inf	## 3.10	## 0.020	## *

```
##
```

```
## Marginal contrasts estimated at DIFFUSION
```

```
## p-value adjustment method: Benjamini & Hochberg (1995)
```

```
table_data_diff <- data |> select(DIFFUSION, LATENCE_BINAIRE) |>
table()
```

```
table_data_count_n <- table_data_diff |> data.frame() |>
group_by(DIFFUSION) |> mutate(N = sum(Freq)) |>
filter(LATENCE_BINAIRE == 1) |> select(-LATENCE_BINAIRE) |>
rename(REACTION=Freq)
```

```
table_data_ci <- table_data_count_n |>
with(binom.confint(REACTION, N, methods="wilson")) |>
select(x, mean, lower, upper) |>
rename(REACTION=x, PROP=mean, LOWER=lower, UPPER=upper)
```


```

table_final_bin <- merge(
  table_data_count_n, table_data_ci, by=c("REACTION")
)

data_test <- data.frame(
  group1 = c("FT_sif", "FT_sif"), group2 = c("FG", "MC"), p="*",
  y.position=c(0.85, 0.95)
)

ggplot(table_final_bin, aes(x=DIFFUSION, y=PROP)) +
  geom_col(fill = "#0073C2FF", width = 0.3) +
  geom_errorbar(aes(ymin = LOWER, ymax = UPPER), width=0.03) +
  theme_minimal() +
  labs(
    title="Proportion de mâles répondant selon le type de diffusion",
    x="Diffusion", y="Proportion de mâle réagissant"
  ) +
  geom_text(
    aes(label = round(PROP,2)), hjust=1.25,
    vjust = -1, color = "black"
  ) +
  ylim(0,1) +
  stat_pvalue_manual(data_test, label = "p", tip.length = 0.01)

```





```
rm(table_data_count_n, table_data_ci, data_test)
```

Les résultats sont significatifs entre les diffusions de sifflements de fauvette à tête noire et les chants de mésange charbonnières ainsi que les chants de fauvette grisette. Or les diffusions de mésanges charbonnières sont les témoins négatifs de diffusion. Aussi, a priori, nous pensions que les fauvettes à tête noire réagiraient moins aux chants de mésange charbonnière (témoin négatif) et de fauvette grisette, ce que nous observons sur le graphique.

## B. Intensité de la réponse

Maintenant, nous voulons tester l'intensité de réponse des oiseaux qui réagissaient à la diffusion (utilisation de `data_reponse`). Nous discuterons de ces résultats une fois l'ensemble analysé.

### 1. Effet des diffusions sur le chant des fauvettes à tête noire

#### a. Tests appariés sur le nombre de strophes avant et après la diffusion i. Statistiques descriptives

Tout d'abord, intéressons nous aux valeurs des statistiques des nombres de strophes avant et après les différentes diffusions pour étudier l'intensité de réaction des fauvettes à tête noire. Nous avons multiplié par 2 les strophes avant la diffusion car nous les avons comptées deux fois moins longtemps (1 minute 30 avant et 3 minutes après).

```
## # A tibble: 12 x 5
##   DIFFUSION AVANT_APRES      n mean   sd
##   <ord>      <fct>      <dbl> <dbl> <dbl>
## 1 FT_comp   STROPHES_AVANT    39  3.54  6.64
## 2 FT_comp   STROPHES_APRES    39  6.95  6.29
## 3 FT_sif    STROPHES_AVANT    43  2.37  4.73
## 4 FT_sif    STROPHES_APRES    43  4.93  4.98
## 5 FT_gaz    STROPHES_AVANT    36  2.44  5.11
## 6 FT_gaz    STROPHES_APRES    36  5.89  6.49
## 7 FJ        STROPHES_AVANT    37  1.68  3.04
## 8 FJ        STROPHES_APRES    37   5     5.97
## 9 FG        STROPHES_AVANT    26  3.77  4.81
## 10 FG       STROPHES_APRES    26  2.96  3.53
## 11 MC       STROPHES_AVANT    24   5     6.75
## 12 MC       STROPHES_APRES    24  4.42  5.44
```

Nous voyons que pour tous les groupes (sauf peut-être pour la fauvette grisette), il y a une différence de moyenne remarquable. Maintenant, nous nous demandons si ces différences sont significatives.

#### ii. Tester l'effet global des diffusions sur le chant

Tout d'abord, nous allons effectuer un test global de l'effet. Avant d'utiliser un t.test apparié, nous devons vérifier que la distribution des moyennes empiriques de la différence testée est normale (ne se fait pas en pratique, mais c'est sympathique à réaliser).

On définit d'abord les fonctions de densité associées aux différences de comptages de strophes.

```
density_func <- function(x_val, densite){
  D <- densite$x
  if ((D[length(D)] > x_val) & (x_val > D[1])){
    x_val <- findInterval(x_val, D)
    y_val <- densite$y[x_val]
  }else{
    y_val <- 0
  }
}
```

```

    return(y_val)
}

dens_diff <- density(data_reponse$STROPHES_APRES - data_reponse$STROPHES_AVANT*2)

```

On cree un data.frame pour tracer ces distribution.

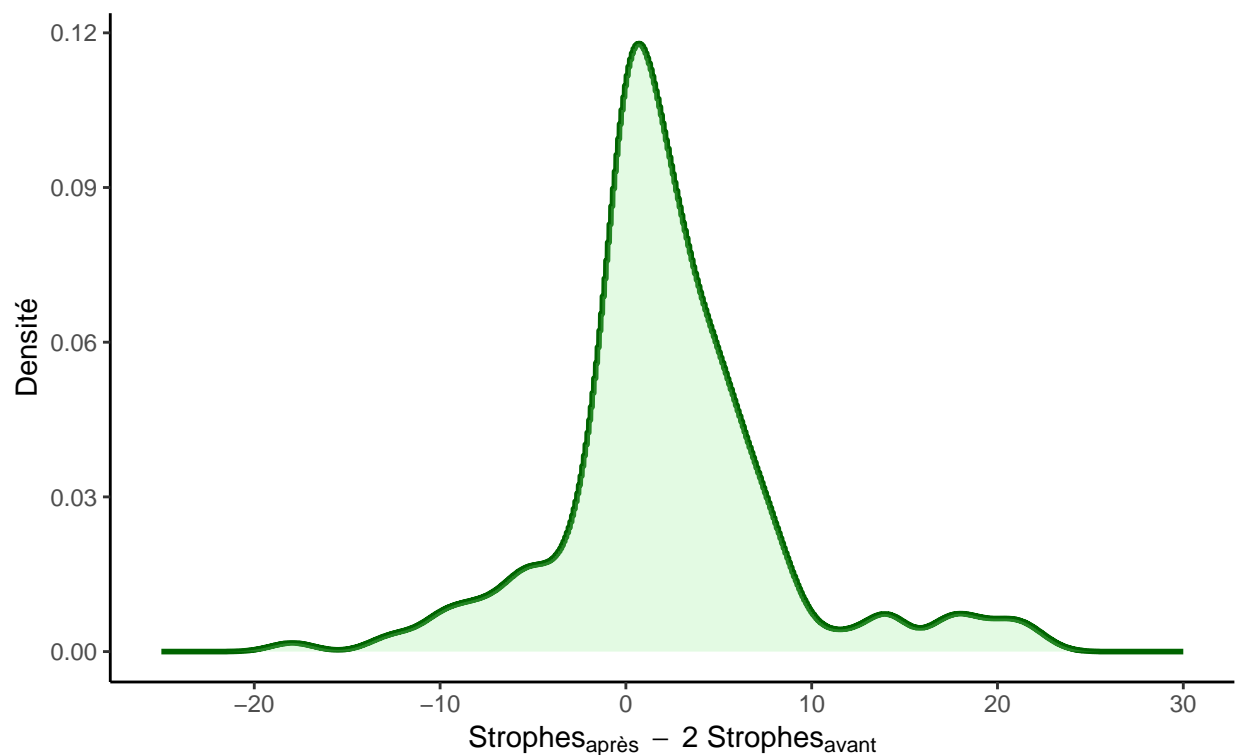
```

modelo_law <- data.frame(Diff_Strophes=seq(-25,30,0.01)) |>
  mutate(
    Densite_Differences =
      sapply(
        Diff_Strophes,
        function(x) density_func(
          x, dens_diff
        )
      )
  )

```

On regarde ce à quoi ressemble les distributions de notre échantillon.

### Densité de la différence entre le nombre de strophes comptées après et avant la diffusion



On fait 1000 fois un échantillonnage de taille égale au nombre de données disponibles dans `data_reponse`, soit 205.

```

mean_diff_data <- function(taille_ech){
  res <- seq(-25,30,0.01) |>
    sample(
      taille_ech, TRUE,
      modelo_law$Densite_Differences
    )
}

```

```

    ) |>
      mean()
    return(res)
  }

moy_emp <- sapply(rep(205, 10000), mean_diff_data) |>
  data.frame() |> setNames("Distribution")


```

On trace enfin la distribution des moyennes empiriques du nombre de strophes avant et après avoir passé la diffusion.

```

## Warning: The dot-dot notation (`.density.`) was deprecated in ggplot2 3.4.0.
## i Please use `after_stat(density)` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.

```



Ainsi, l'utilisation d'un t.test apparié est justifiée car la moyenne empirique de STROPHES\_APRES - 2\*STROPHES\_AVANT suit bien une loi normale grâce à la taille du jeu de données dont nous disposons. Pour le t.test apparié, l'homoscédasticité n'est pas supposée donc nous ne la testons pas.

```

##
## Paired t-test
##
## data: data_reponse$STROPHES_APRES and data_reponse$STROPHES_AVANT * 2
## t = 5.4038, df = 204, p-value = 1.811e-07
## alternative hypothesis: true mean difference is not equal to 0

```


```
## 95 percent confidence interval:
## 1.409685 3.029340
## sample estimates:
## mean difference
## 2.219512

## # A tibble: 1 x 2
##   `Moyenne de après - avant` `Taille de l'effet`
##   <dbl>                      <dbl>
## 1      2.22                  0.377
```

Il y a donc bien un effet de la diffusion sur le nombre de chant, c'est à dire en moyenne environ 2 strophes de plus prononcées après par rapport à avant la diffusion. Mais la taille d'effet étant assez faible, nous allons maintenant rentrer un peu plus dans les détails.

iii. Tester l'effet de chaque type diffusion sur le chant

Pour préciser cet effet, revenons à nos groupes par type de diffusion. Avant de faire des tests, représentons nos données.



Nous allons faire, après vérification des hypothèses de test, une ANOVA sur mesures répétées. Cette ANOVA permet d'apparier les données de comptage de strophes avant et après (comme si c'était deux traitements différents) et d'étudier la différence entre ces deux groupes selon d'autres facteurs, ici un seul, le type de diffusion.

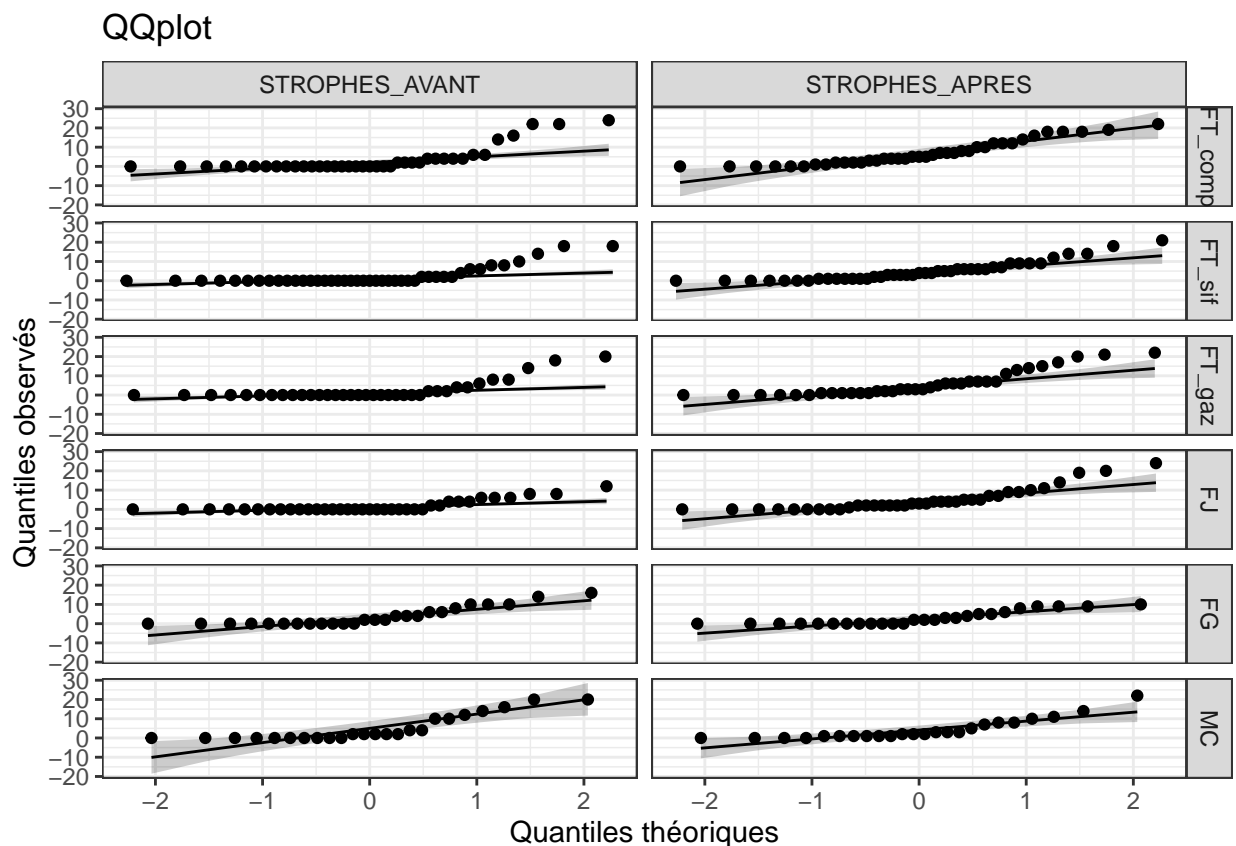
Avant de faire ce modèle, assurons nous que l'hypothèse de normalité des résidus est vérifiée. Dans un premier temps, nous réalisons un test de Shapiro-Wilk, bien que très stringent...

```
## # A tibble: 12 x 4
##   DIFFUSION AVANT_APRES statistic p
```

```
##      <ord>      <fct>          <dbl>    <dbl>
##  1 FT_comp    STROPHES_AVANT    0.591 3.19e- 9
##  2 FT_comp    STROPHES_APRES    0.893 1.41e- 3
##  3 FT_sif     STROPHES_AVANT    0.576 6.15e-10
##  4 FT_sif     STROPHES_APRES    0.852 5.77e- 5
##  5 FT_gaz     STROPHES_AVANT    0.556 2.86e- 9
##  6 FT_gaz     STROPHES_APRES    0.818 3.83e- 5
##  7 FJ         STROPHES_AVANT    0.626 1.71e- 8
##  8 FJ         STROPHES_APRES    0.781 5.43e- 6
##  9 FG         STROPHES_AVANT    0.792 1.31e- 4
## 10 FG         STROPHES_APRES    0.797 1.57e- 4
## 11 MC         STROPHES_AVANT    0.750 4.90e- 5
## 12 MC         STROPHES_APRES    0.774 1.13e- 4
```

Comme nous pouvions nous attendre, le test conclut à la non normalité de nos distributions. Nous représentons alors les qqplot.

```
ggqqplot(data_reponse_long, "STROPHES", ggtheme = theme_bw()) +
  facet_grid(DIFFUSION ~ AVANT_APRES, labeller = "label_value") +
  theme_bw() +
  labs(title="QQplot", x="Quantiles théoriques", y="Quantiles observés")
```



Après cela et sachant que l'ANOVA est relativement robuste à l'hypothèse de normalité, nous allons l'utiliser.

```
## ANOVA Table (type III tests)
##
##      Effect DFn DFd      F      p p<.05  ges
##  1      DIFFUSION    5 199 0.970 4.37e-01 0.017
```

```
## 2          AVANT_APRES    1 199 21.543 6.27e-06    * 0.029
## 3 DIFFUSION:AVANT_APRES    5 199  3.607 4.00e-03    * 0.024
```

On retrouve encore la différence significative entre le comptage avant et après du nombre de strophes, et comme il existe une interaction avec le type de diffusion, nous allons décomposer cet effet.

```
## # A tibble: 6 x 10
##   DIFFUSION Effect      DFn  DFd      F      p `p<.05`  ges p.adj p.adj.signif
##   <ord>      <chr>    <dbl> <dbl>    <dbl>    <dbl> <chr>    <dbl> <dbl> <chr>
## 1 FT_comp  AVANT_A~      1    38 10.1    3  e-3  "*"    0.067 0.006 **
## 2 FT_sif   AVANT_A~      1    42  8.39   6  e-3  "*"    0.066 0.009 **
## 3 FT_gaz   AVANT_A~      1    35 12.2    1  e-3  "*"    0.082 0.003 **
## 4 FJ       AVANT_A~      1    36 14.5    5.29e-4  "*"    0.112 0.003 **
## 5 FG       AVANT_A~      1    25  0.714 4.06e-1  ""     0.009 0.487 ns
## 6 MC       AVANT_A~      1    23  0.37   5.49e-1  ""     0.002 0.549 ns
```

Ainsi, on retrouve bien un effet significatif de la diffusion (c'est à dire une augmentation du nombre de strophes après) pour tous les types de diffusions, sauf pour la fauvette grisette et la mésange charbonnière.

```
## # A tibble: 6 x 3
##   DIFFUSION `Moyenne de (après - avant)` `Taille de l'effet`
##   <ord>                                <dbl>          <dbl>
## 1 FT_comp                                3.41            0.508
## 2 FT_sif                                2.56            0.442
## 3 FT_gaz                                3.44            0.581
## 4 FJ                                    3.32            0.626
## 5 FG                                   -0.808          -0.166
## 6 MC                                   -0.583          -0.124
```

En ce qui concerne la taille d'effet, nous voyons qu'elle est plus grande que ce que nous avons obtenu sans distinguer les types de diffusion.

Nous pouvons donc conclure que tous les chants de fauvette à tête noire, qu'ils soient complets ou non, et les chants de fauvette des jardins, font réagir les fauvettes à tête noire.

La réaction à l'encontre de la fauvette des jardins peut s'expliquer par la proximité phylogénétique des deux espèces, la ressemblance de leur chant et leurs niches écologiques relativement proches.

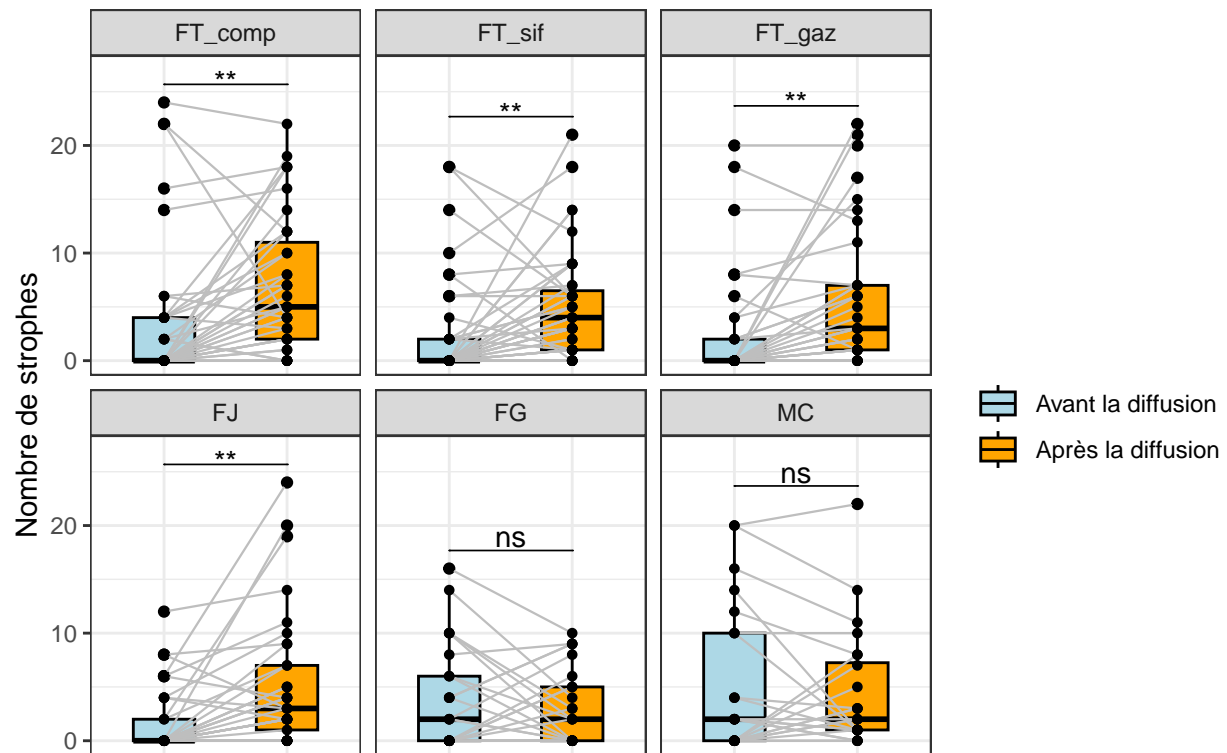
Finalement représentons les données en indiquant les différences significatives.

On crée d'abord un data.frame contenant les niveaux de significativité.

```
# Cela donne les memes resultats que dans le chunk `paired_anova_groups`
stat_result_paired <- data_reponse_long |> group_by(DIFFUSION) |>
  t_test(STROPHES ~ AVANT_APRES, paired=TRUE) |>
  adjust_pvalue(method = "fdr") |>
  add_significance() |> add_xy_position(x = "AVANT_APRES")
```

Et on trace ensuite le graphique.

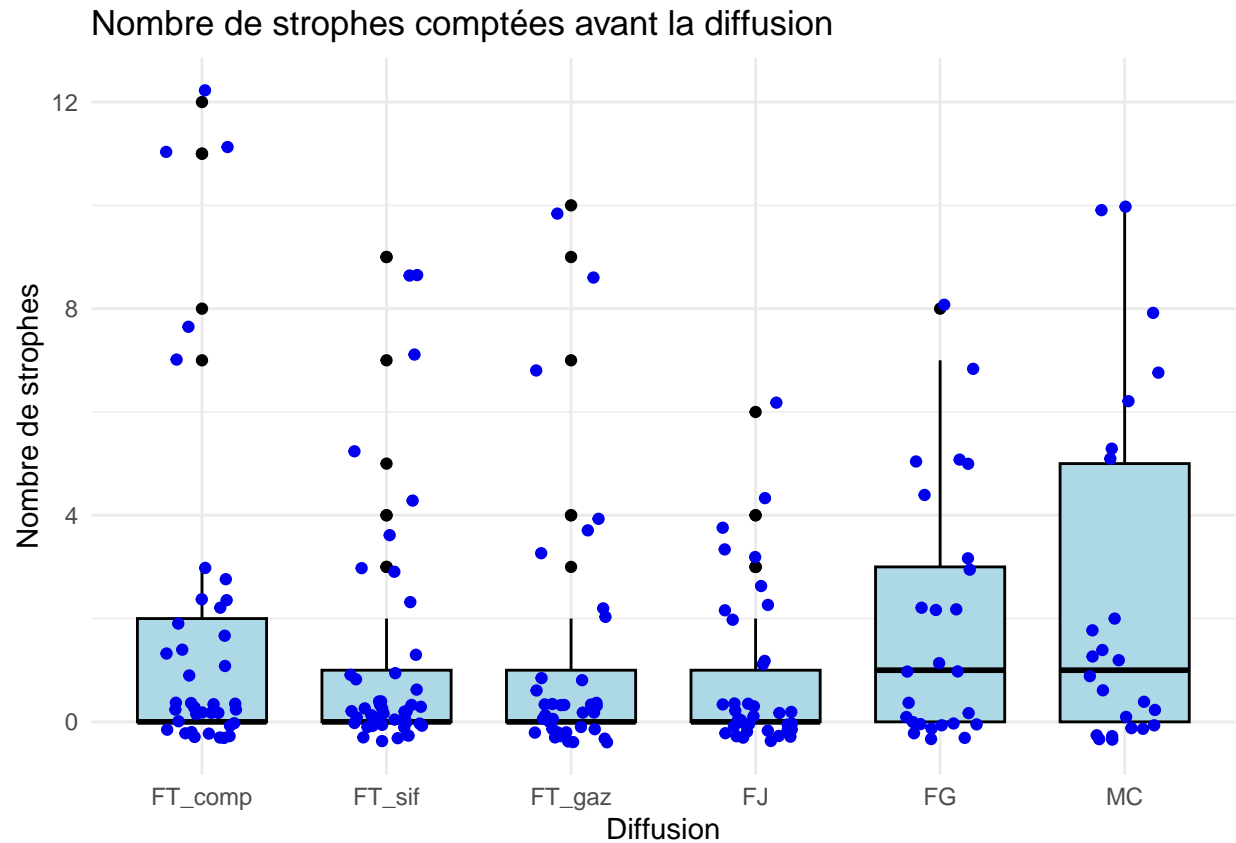
## Réponse en terme de chant aux différents types de diffusion



**b. Test de l'effet du type de diffusion sur la réponse de type chant** Avant toute chose, demandons-nous si nous pouvons comparer le nombre de strophes après diffusion de chaque groupe. Pour cela, il faudrait que nous n'observions pas de différence entre le nombre de strophes prononcées avant la diffusion. En effet, nous avons randomisé l'ordre de diffusion des différents chants et normalement, de telles différences devraient être effacées par le hasard, mais compte tenu du nombre de répétition de notre expérience et de l'existence de potentiels autres biais (le comportement des expérimentateurs avant la diffusion de certains chants par exemple, bien que seul la personne en charge de la diffusion connaissait cette information en règle générale), nous devons vérifier que de telles différences n'existent pas dans notre jeu de données.

### i. Nombre de strophes avant la diffusion

Tout d'abord, regardons s'il y a une différence de nombre de strophes avant diffusion selon les types de diffusion.



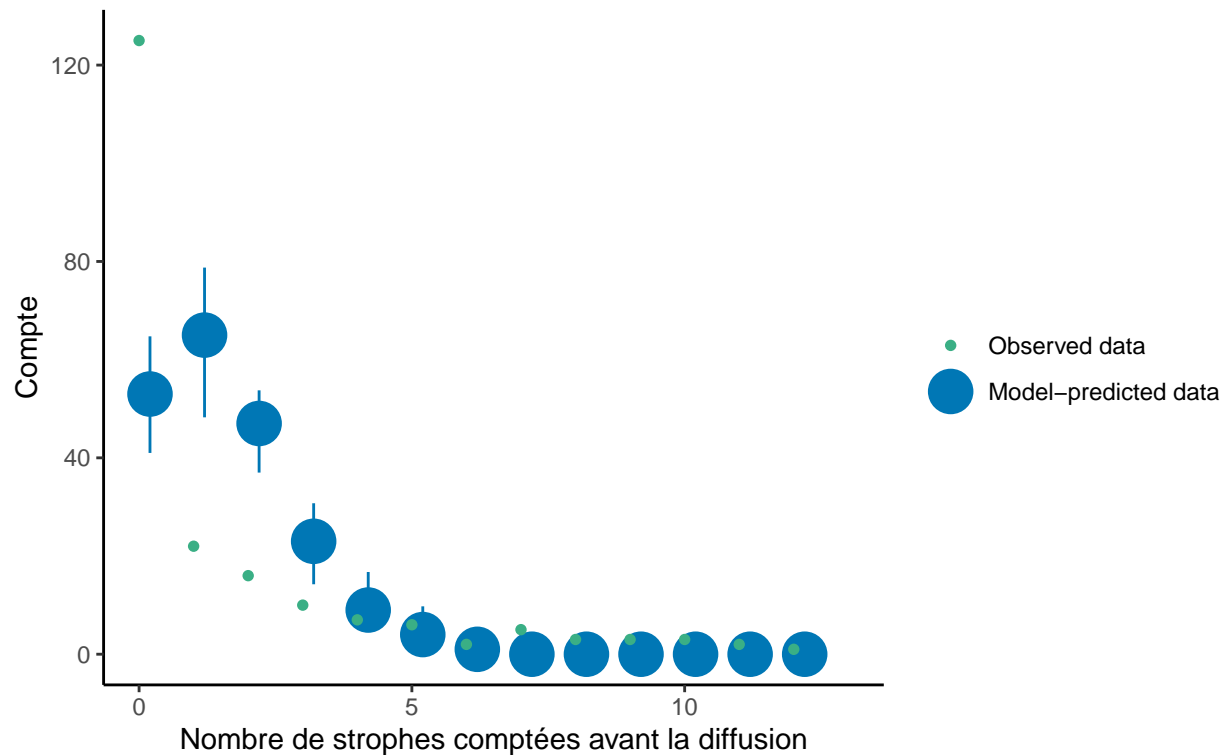
```
## # A tibble: 6 x 4
##   DIFFUSION      n mean   sd
##   <ord>      <dbl> <dbl> <dbl>
## 1 FT_comp      39 1.77  3.32
## 2 FT_sif      43 1.19  2.36
## 3 FT_gaz      36 1.22  2.55
## 4 FJ          37 0.838 1.52
## 5 FG          26 1.88  2.40
## 6 MC          24 2.5   3.38
```

Sur le graphique ci-dessus, il n'est pas évident que le nombre de strophes avant diffusion est le même quelque soit le groupe, particulièrement pour les deux chants pour lesquels il n'y avait pas de réponse à la diffusion, celui de la mésange charbonnière et de la fauvette grisette.

On cherche d'abord quel modèle utiliser pour nos données de comptage. Nous ne reproduirons pas cette recherche systématiquement (sauf en cas de résultats différent) afin de raccourcir le rapport, mais il est bon de noter que nous l'avons effectué pour chaque test afin d'être sûr de la pertinence du modèle statistique que nous utilisons. On commence par une régression de Poisson car nous testons des données de comptage :



## Comparaison de nos données au modèle fitté

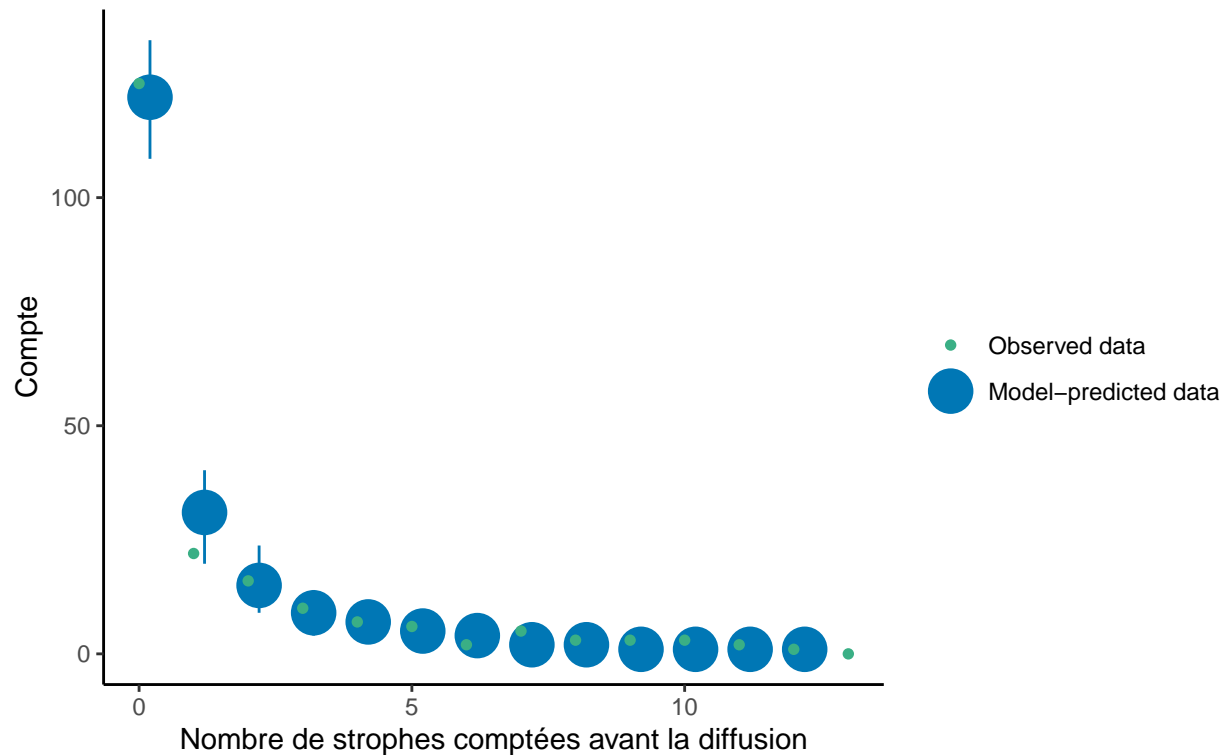


```
## # Overdispersion test
##
##      dispersion ratio = 4.532
##  Pearson's Chi-Squared = 901.887
##      p-value = < 0.001
## Overdispersion detected.
## # Distribution of Model Family
##
## Predicted Distribution of Residuals
##
## Distribution Probability
##      cauchy      38%
##      normal      25%
##      tweedie      22%
##
## Predicted Distribution of Response
##
##      Distribution Probability
##      beta-binomial      44%
## neg. binomial (zero-infl.) 34%
##      poisson (zero-infl.) 16%
```

Ici, les prédictions de ce même modèle ne correspondent pas du tout à ce que nous avons. Il y a de la surdispersion et nous allons essayer de corriger cela en utilisant une régression binomiale négative (de plus, la fonction `check_distribution` nous propose cette distribution comme la plus probable).

```
## Warning: Removed 24 rows containing missing values or values outside the scale range
## (`geom_pointrange()`).
## Warning: Removed 23 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

## Comparaison de nos données au modèle fitté



```
## # Overdispersion test
##
## dispersion ratio = 0.654
## p-value = 0.344
## No overdispersion detected.
```

Cette fois-ci, les prédictions sont bien meilleures et la surdispersion a été corrigée. Nous pouvons également réaliser un BIC qui pourrait participer à notre prise de décision. Nous l'utilisons sur les deux modèles précédents ainsi que sur un modèle de Poisson et un modèle binomial négatif zero-inflated.

```
## [1] "Le BIC de la régression poissonnienne est de 977 alors que celui de la régression binomiale négative est de 1000"
```

Ici, nous utilisons donc le modèle binomial négatif qui nous donne :

```
##
## Call:
## MASS::glm.nb(formula = STROPHES_AVANT ~ DIFFUSION, data = data_reponse,
## init.theta = 0.294722102, link = log)
##
## Coefficients:
## Estimate Std. Error z value Pr(>|z|)
## (Intercept) 0.3858208 0.1443280 2.673 0.00751 **
```

```

## DIFFUSION.L 0.3275432 0.3580536 0.915 0.36030
## DIFFUSION.Q 0.7130126 0.3551134 2.008 0.04466 *
## DIFFUSION.C -0.0001903 0.3540656 -0.001 0.99957
## DIFFUSION^4 -0.1660648 0.3519393 -0.472 0.63703
## DIFFUSION^5 -0.3619488 0.3484040 -1.039 0.29886
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(0.2947) family taken to be 1)
##
## Null deviance: 171.25 on 204 degrees of freedom
## Residual deviance: 165.38 on 199 degrees of freedom
## AIC: 637.37
##
## Number of Fisher Scoring iterations: 1
##
##
## Theta: 0.2947
## Std. Err.: 0.0501
##
## 2 x log-likelihood: -623.3710
## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.
## Marginal Contrasts Analysis
##
## Level1 | Level2 | Difference | 95% CI | SE | df | z | p | p.signif
## -----
## FG | MC | -0.28 | [-1.91, 1.35] | 0.56 | Inf | -0.51 | 0.705 | ns
## FJ | FG | -0.81 | [-2.35, 0.73] | 0.52 | Inf | -1.55 | 0.517 | ns
## FJ | MC | -1.09 | [-2.65, 0.47] | 0.53 | Inf | -2.06 | 0.517 | ns
## FT_comp | FG | -0.06 | [-1.54, 1.41] | 0.50 | Inf | -0.13 | 0.948 | ns
## FT_comp | FJ | 0.75 | [-0.65, 2.14] | 0.47 | Inf | 1.57 | 0.517 | ns
## FT_comp | FT_gaz | 0.37 | [-1.00, 1.74] | 0.47 | Inf | 0.79 | 0.622 | ns
## FT_comp | FT_sif | 0.40 | [-0.91, 1.71] | 0.45 | Inf | 0.89 | 0.622 | ns
## FT_comp | MC | -0.35 | [-1.84, 1.15] | 0.51 | Inf | -0.68 | 0.622 | ns
## FT_gaz | FG | -0.43 | [-1.95, 1.09] | 0.52 | Inf | -0.84 | 0.622 | ns
## FT_gaz | FJ | 0.38 | [-1.06, 1.82] | 0.49 | Inf | 0.77 | 0.622 | ns
## FT_gaz | MC | -0.72 | [-2.25, 0.82] | 0.52 | Inf | -1.36 | 0.517 | ns
## FT_sif | FG | -0.46 | [-1.93, 1.00] | 0.50 | Inf | -0.93 | 0.622 | ns
## FT_sif | FJ | 0.35 | [-1.04, 1.73] | 0.47 | Inf | 0.74 | 0.622 | ns
## FT_sif | FT_gaz | -0.03 | [-1.39, 1.33] | 0.46 | Inf | -0.06 | 0.948 | ns
## FT_sif | MC | -0.75 | [-2.23, 0.74] | 0.51 | Inf | -1.47 | 0.517 | ns
##
## Marginal contrasts estimated at DIFFUSION
## p-value adjustment method: Benjamini & Hochberg (1995)

```

D'après les résultats des tests, il n'y a donc pas de différences significatives entre les nombres de strophes chantées avant la diffusion. Nous comparerons donc directement les nombres de strophes chantées après diffusion.


## ii. Nombre de strophes après la diffusion

Comme précédemment, nous commençons par représenter nos données et certaines statistiques classiques (moyenne et écart-type en plus de la médiane et des quartiles sur les boxplots).

```
## Warning: Removed 21 rows containing missing values or values outside the scale range
```

```
## (`geom_point()`).
```

## Nombre de strophes comptées après la diffusion



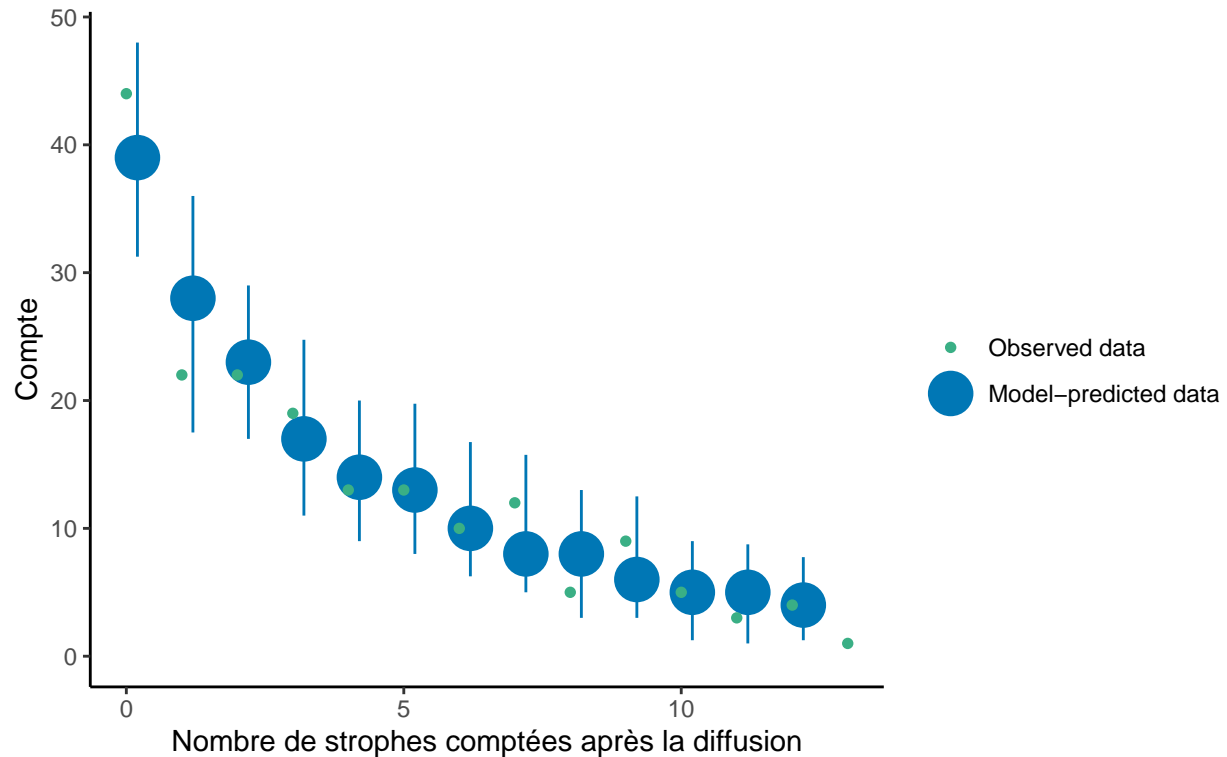
```
## # A tibble: 6 x 4
```

```
##   DIFFUSION      n mean  sd
##   <ord>      <dbl> <dbl> <dbl>
## 1 FT_comp    39  6.95  6.29
## 2 FT_sif    43  4.93  4.98
## 3 FT_gaz    36  5.89  6.49
## 4 FJ        37  5    5.97
## 5 FG        26  2.96  3.53
## 6 MC        24  4.42  5.44
```

```
## Warning: Removed 41 rows containing missing values or values outside the scale range
## (`geom_pointrange()`).
```

```
## Warning: Removed 40 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

## Comparaison de nos données au modèle fitté



Ici encore, nous utilisons la régression binomiale négative qui nous donne le meilleur BIC et visiblement de bonnes prédictions.

```
mod_apres_bn |> BIC()
```

```
## [1] 1148.215
```

```
mod_apres_bn |> estimate_contrasts(p_adjust = "fdr") |>
  add_significance()
```

```
## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.
```

```
## Marginal Contrasts Analysis
```

```
##
```

## Level1	## Level2	## Difference	## 95% CI	## SE	## df	## z	## p	## p.signif
## FG	## MC	-0.40	[-1.39, 0.59]	0.34	Inf	-1.18	0.446	ns
## FJ	## FG	0.52	[-0.38, 1.42]	0.31	Inf	1.71	0.327	ns
## FJ	## MC	0.12	[-0.78, 1.02]	0.31	Inf	0.40	0.763	ns
## FT_comp	## FG	0.85	[-0.03, 1.74]	0.30	Inf	2.83	0.069	ns
## FT_comp	## FJ	0.33	[-0.45, 1.10]	0.26	Inf	1.25	0.446	ns
## FT_comp	## FT_gaz	0.17	[-0.61, 0.94]	0.26	Inf	0.63	0.682	ns
## FT_comp	## FT_sif	0.34	[-0.40, 1.09]	0.25	Inf	1.35	0.444	ns
## FT_comp	## MC	0.45	[-0.43, 1.34]	0.30	Inf	1.51	0.397	ns
## FT_gaz	## FG	0.69	[-0.21, 1.59]	0.31	Inf	2.24	0.187	ns
## FT_gaz	## FJ	0.16	[-0.63, 0.96]	0.27	Inf	0.60	0.682	ns
## FT_gaz	## MC	0.29	[-0.61, 1.19]	0.31	Inf	0.94	0.581	ns
## FT_sif	## FG	0.51	[-0.37, 1.38]	0.30	Inf	1.71	0.327	ns

```
## FT_sif | FJ | -0.01 | [-0.78, 0.75] | 0.26 | Inf | -0.05 | 0.957 | ns
## FT_sif | FT_gaz | -0.18 | [-0.94, 0.59] | 0.26 | Inf | -0.68 | 0.682 | ns
## FT_sif | MC | 0.11 | [-0.77, 0.99] | 0.30 | Inf | 0.37 | 0.763 | ns
##
## Marginal contrasts estimated at DIFFUSION
## p-value adjustment method: Benjamini & Hochberg (1995)
```

Ici, aucune différence n'est significative donc nous ne pouvons rien conclure, mais nous voyons néanmoins que la p-value est plus faible pour la comparaison entre le chant complet de fauvette à tête noire et le chant de fauvette grisette. Cela n'est pas très étonnant car premièrement, nous n'avons pas beaucoup de données pour chaque sous-groupe, et ensuite, ces données étant extrêmement bruitées, il est difficile d'en tirer beaucoup d'information.

Afin de faire des hypothèses quant aux résultats que nous pourrions obtenir si nous avions plus de données, nous pouvons nous baser sur les comparaisons non significatives de notre jeu de données. Ces dernières nous indiquent que les fauvettes à tête noire réagissent plus en terme de chant à celui de leur espèce ou d'une espèce proche comme la fauvette des jardins alors que cette réponse est moins importante voire absente face aux mésanges charbonnières et aux fauvettes grisettes.

D'ailleurs, ces tendances sont confirmées lorsque nous réalisons un test non paramétrique. Etant donné que ces tests sont généralement moins puissants que les paramétriques applicables aux données, il nous pose question d'obtenir moins de résultats significatifs avec ces derniers... Avons nous bien choisi nos modèles ? Est-ce vraiment le "manque de données" qui nous limite dans ce cas précis ?

```
##
## Kruskal-Wallis rank sum test
##
## data: STROPHES_APRES by DIFFUSION
## Kruskal-Wallis chi-squared = 25.109, df = 5, p-value = 0.0001328
## # A tibble: 15 x 9
##   .y.      group1 group2   n1   n2 statistic      p    p.adj p.adj.signif
##   * <chr>      <chr> <chr> <int> <int>      <dbl> <dbl> <dbl> <chr>
## 1 STROPHES_AP~ FT_co~ FT_sif    65    63     0.107 9.15e-1 0.915    ns
## 2 STROPHES_AP~ FT_co~ FT_gaz    65    63    -0.659 5.10e-1 0.637    ns
## 3 STROPHES_AP~ FT_co~ FJ        65    63    -1.08  2.80e-1 0.420    ns
## 4 STROPHES_AP~ FT_co~ FG        65    63    -3.56  3.69e-4 0.00276 **
## 5 STROPHES_AP~ FT_co~ MC        65    60    -3.17  1.50e-3 0.00562 **
## 6 STROPHES_AP~ FT_sif FT_gaz    63    63    -0.761 4.47e-1 0.609    ns
## 7 STROPHES_AP~ FT_sif FJ        63    63    -1.18  2.38e-1 0.397    ns
## 8 STROPHES_AP~ FT_sif FG        63    63    -3.64  2.72e-4 0.00276 **
## 9 STROPHES_AP~ FT_sif MC        63    60    -3.26  1.13e-3 0.00562 **
## 10 STROPHES_AP~ FT_gaz FJ        63    63    -0.418 6.76e-1 0.780    ns
## 11 STROPHES_AP~ FT_gaz FG        63    63    -2.88  3.98e-3 0.0119   *
## 12 STROPHES_AP~ FT_gaz MC        63    60    -2.50  1.23e-2 0.0297   *
## 13 STROPHES_AP~ FJ      FG        63    63    -2.46  1.38e-2 0.0297   *
## 14 STROPHES_AP~ FJ      MC        63    60    -2.09  3.65e-2 0.0684    ns
## 15 STROPHES_AP~ FG      MC        63    60     0.340 7.34e-1 0.786    ns
```

Avec un modèle mixte, on baisse aussi très légèrement le BIC par rapport au précédent, mais les résultats restent très semblable et détectent toujours moins de différences que les tests paramétriques.

```
mod_apres_mixed <- lme4::glmer.nb(STROPHES_APRES ~ DIFFUSION + (1|ID_MALE), data=data_reponse)
mod_apres_mixed > BIC()
```

```
## [1] 1144.927
```

```

mod_apres_bn |> BIC()

## [1] 1148.215

mod_apres_mixed |> estimate_contrasts(p_adjust = "fdr") |> add_significance()

## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.

## Marginal Contrasts Analysis
##
## Level1 | Level2 | Difference |          95% CI | SE | df | z | p | p.signif
## -----|-----|-----|-----|-----|-----|-----|-----|-----|-----
## FG      | MC      | -0.32 | [-1.28, 0.64] | 0.33 | Inf | -0.97 | 0.531 | ns
## FJ      | FG      | 0.50 | [-0.37, 1.38] | 0.30 | Inf | 1.68 | 0.277 | ns
## FJ      | MC      | 0.18 | [-0.68, 1.04] | 0.29 | Inf | 0.62 | 0.613 | ns
## FT_comp | FG      | 0.88 | [ 0.01, 1.75] | 0.30 | Inf | 2.95 | 0.047 | *
## FT_comp | FJ      | 0.37 | [-0.39, 1.14] | 0.26 | Inf | 1.44 | 0.323 | ns
## FT_comp | FT_gaz  | 0.15 | [-0.61, 0.90] | 0.26 | Inf | 0.57 | 0.613 | ns
## FT_comp | FT_sif  | 0.38 | [-0.35, 1.11] | 0.25 | Inf | 1.54 | 0.309 | ns
## FT_comp | MC      | 0.56 | [-0.29, 1.41] | 0.29 | Inf | 1.92 | 0.275 | ns
## FT_gaz  | FG      | 0.73 | [-0.16, 1.62] | 0.30 | Inf | 2.41 | 0.119 | ns
## FT_gaz  | FJ      | 0.23 | [-0.55, 1.01] | 0.27 | Inf | 0.86 | 0.535 | ns
## FT_gaz  | MC      | 0.41 | [-0.47, 1.29] | 0.30 | Inf | 1.36 | 0.323 | ns
## FT_sif  | FG      | 0.49 | [-0.36, 1.34] | 0.29 | Inf | 1.71 | 0.277 | ns
## FT_sif  | FJ      | -8.43e-03 | [-0.74, 0.72] | 0.25 | Inf | -0.03 | 0.973 | ns
## FT_sif  | FT_gaz  | -0.24 | [-0.98, 0.51] | 0.25 | Inf | -0.93 | 0.531 | ns
## FT_sif  | MC      | 0.17 | [-0.66, 1.01] | 0.29 | Inf | 0.61 | 0.613 | ns
##
## Marginal contrasts estimated at DIFFUSION
## p-value adjustment method: Benjamini & Hochberg (1995)

```

A l'avenir, quand le BIC sera plus élevé, nous utiliserons le modèle mixte correspondant.


**2. Effet des diffusions sur le nombre de cris** Après avoir étudié le chant réponse aux différentes diffusion, nous nous intéressons maintenant à la réponse de type cris. Pour cela, nous ne disposons que de la variable CRIS qui correspond au nombre de cris poussés du début de la diffusion à la fin du temps d'observation (soit 3 minutes après).

Nous ne testerons alors que le nombre de cris selon le type de diffusion.

```

## # A tibble: 6 x 4
##   DIFFUSION      n mean   sd
##   <ord>      <dbl> <dbl> <dbl>
## 1 FT_comp      39  13.6  27.0
## 2 FT_sif       43  17.3  33.5
## 3 FT_gaz       36  12.8  38.3
## 4 FJ           37  25.3  49.9
## 5 FG           26  31.4  55.4
## 6 MC           24  21.4  31.5

```



Premièrement, nous voyons dans le tableau que les moyennes ne semblent pas suivre le même schéma que dans la section précédente. Nous avons en moyenne plus de cris pour les chants hétérospécifiques. De plus, les écarts types étant très importants, cela semble peu probable que nous observions un effet très net du type de diffusion sur le nombre de cris.

Sur les boxplot ensuite, nous remarquons qu'il y a beaucoup de valeurs extrêmes et que les médianes semblent très proches les unes des autres. On voit aussi que les médianes de FG et MC sont un peu plus élevées, ainsi que celle de FJ dans une moindre mesure.

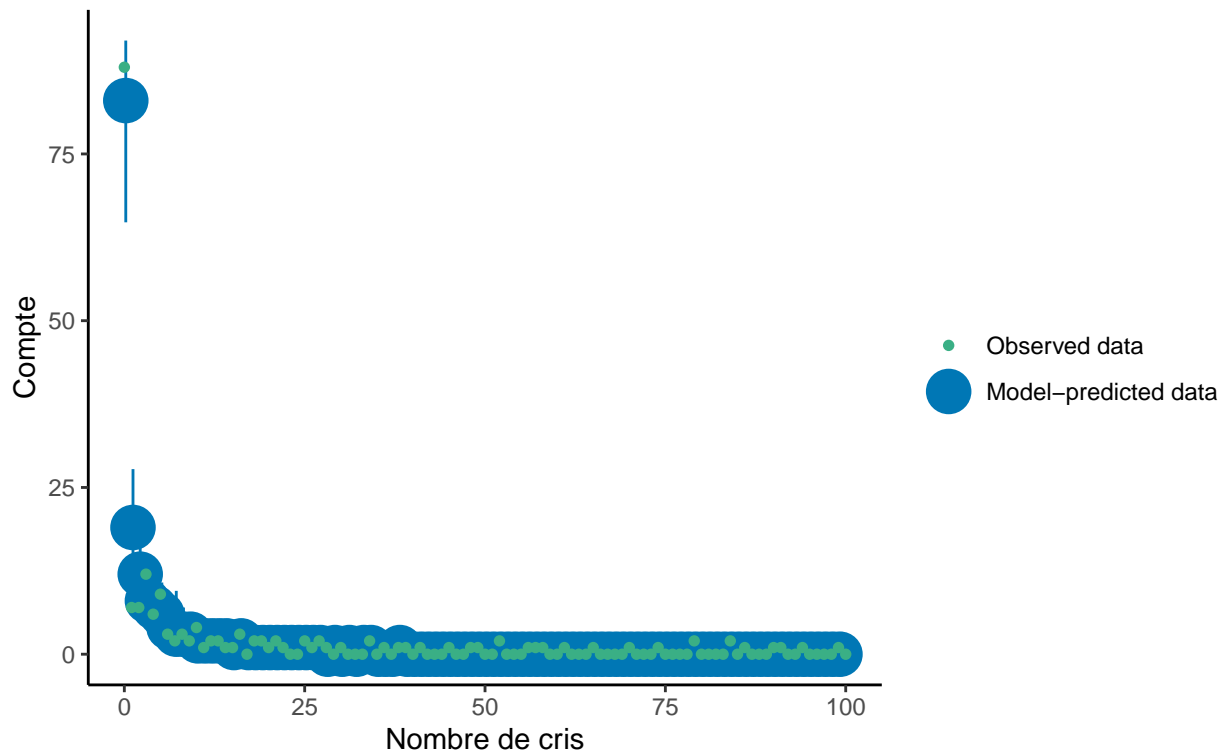
On modélise encore ces données avec un modèle binomial négatif.

```
## Warning: Removed 199 rows containing missing values or values outside the scale range
## (`geom_pointrange()`).
```

```
## Warning: Removed 198 rows containing missing values or values outside the scale range
## (`geom_point()`).
```



## Comparaison de nos données au modèle fitté



Encore une fois, ce modèle fait de bonnes prédictions. Regardons les résultats qu'il nous donne :

```
## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: Negative Binomial(0.2441) ( log )
## Formula: CRIS ~ DIFFUSION + (1 | ID_MALE)
## Data: data_reponse
##
##      AIC      BIC   logLik deviance df.resid
##  1297.6   1324.2   -640.8   1281.6     197
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -0.4932 -0.4808 -0.4188  0.1219  5.2741
##
## Random effects:
## Groups Name      Variance Std.Dev.
## ID_MALE (Intercept) 1.267    1.125
## Number of obs: 205, groups: ID_MALE, 11
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    2.3661    0.3766   6.282 3.34e-10 ***
## DIFFUSION.L     0.4856    0.4274   1.136  0.256
## DIFFUSION.Q     0.3285    0.4215   0.779  0.436
## DIFFUSION.C     0.2157    0.4140   0.521  0.602
## DIFFUSION^4    -0.3580    0.3733  -0.959  0.338
```

```

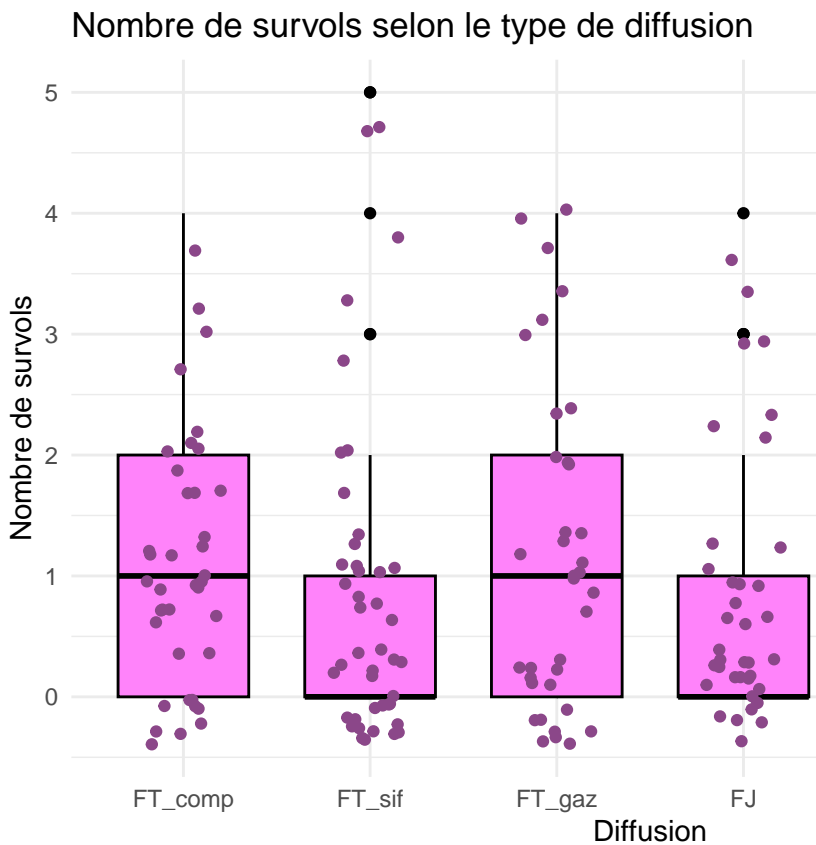
## DIFFUSION^5 -0.0244      0.3902 -0.063      0.950
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) DIFFUSION.L DIFFUSION.Q DIFFUSION.C DIFFUSION^4
## DIFFUSION.L  0.099
## DIFFUSION.Q  0.013  0.159
## DIFFUSION.C -0.039  0.043      0.213
## DIFFUSION^4  0.010  0.045      0.060      0.129
## DIFFUSION^5  0.007  0.003     -0.012     -0.062      0.009

## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.

## Marginal Contrasts Analysis
##
## Level1 | Level2 | Difference |          95% CI | SE | df |          z |          p | p.signif
## -----|-----|-----|-----|-----|----|-----|-----|-----|
## FG      | MC      | -0.24 | [-2.13, 1.64] | 0.64 | Inf | -0.38 | 0.960 | ns
## FJ      | FG      | -0.54 | [-2.13, 1.06] | 0.54 | Inf | -0.99 | 0.800 | ns
## FJ      | MC      | -0.78 | [-2.69, 1.13] | 0.65 | Inf | -1.20 | 0.800 | ns
## FT_comp | FG      | -0.49 | [-2.12, 1.13] | 0.55 | Inf | -0.89 | 0.800 | ns
## FT_comp | FJ      | 0.04 | [-1.57, 1.65] | 0.55 | Inf | 0.08 | > .999 | ns
## FT_comp | FT_gaz  | -4.47e-04 | [-1.56, 1.55] | 0.53 | Inf | -8.43e-04 | > .999 | ns
## FT_comp | FT_sif  | -0.36 | [-1.82, 1.11] | 0.50 | Inf | -0.71 | 0.800 | ns
## FT_comp | MC      | -0.74 | [-2.52, 1.05] | 0.61 | Inf | -1.21 | 0.800 | ns
## FT_gaz  | FG      | -0.49 | [-2.16, 1.17] | 0.57 | Inf | -0.87 | 0.800 | ns
## FT_gaz  | FJ      | 0.04 | [-1.63, 1.72] | 0.57 | Inf | 0.08 | > .999 | ns
## FT_gaz  | MC      | -0.74 | [-2.55, 1.07] | 0.62 | Inf | -1.19 | 0.800 | ns
## FT_sif  | FG      | -0.14 | [-1.79, 1.51] | 0.56 | Inf | -0.25 | > .999 | ns
## FT_sif  | FJ      | 0.40 | [-1.20, 2.00] | 0.54 | Inf | 0.73 | 0.800 | ns
## FT_sif  | FT_gaz  | 0.35 | [-1.20, 1.91] | 0.53 | Inf | 0.67 | 0.800 | ns
## FT_sif  | MC      | -0.38 | [-2.19, 1.42] | 0.61 | Inf | -0.62 | 0.800 | ns
##
## Marginal contrasts estimated at DIFFUSION
## p-value adjustment method: Benjamini & Hochberg (1995)

```

Finalement, le nombre de cris n'est significativement plus grand pour aucun groupe. Nous retiendrons tout de même que la tendance pour le nombre de cris semblait contraire à celle pour le nombre de chant ce qui pourrait indiquer que ce type de réponse est plutôt dirigé de manière non spécifique quand l'oiseau est dérangé. Le chant quant à lui réservé aux congénères des fauvettes à tête noire jouerait d'avantage un rôle dans la réponse territoriale et sexuelle des oiseaux.

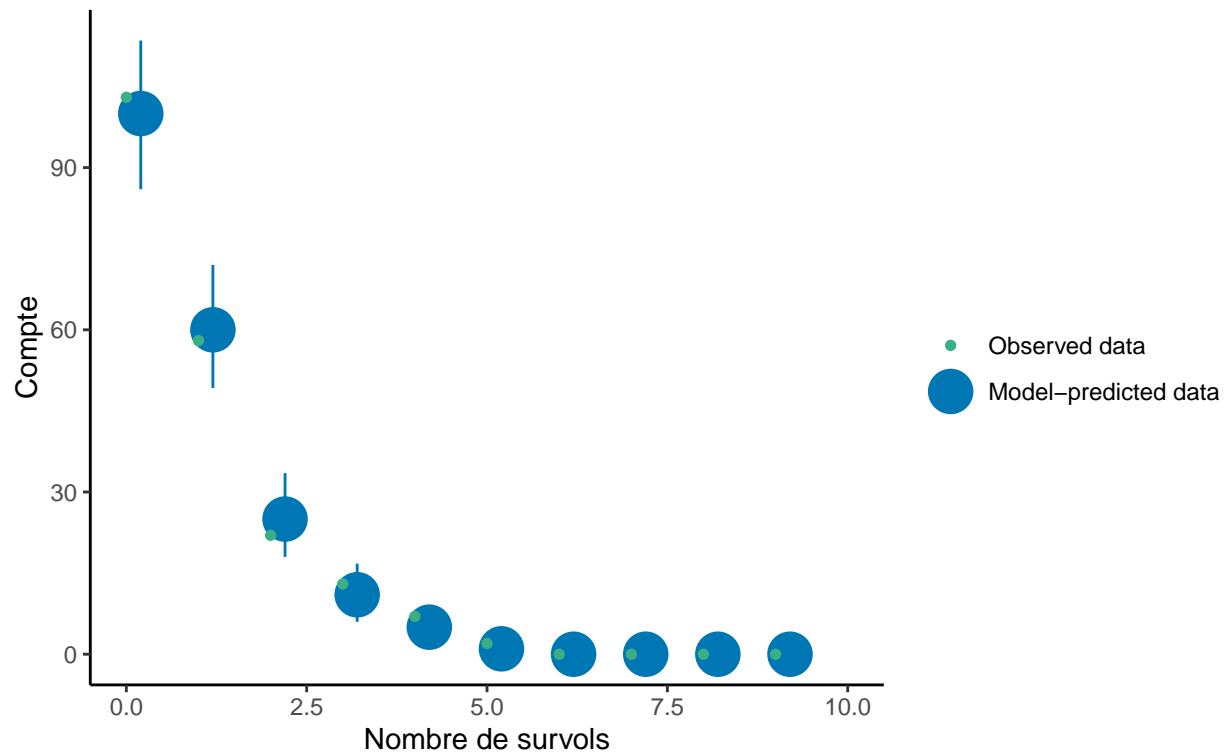


### 3. Effet des diffusions sur le nombre de survols

```
## # A tibble: 6 x 4
##   DIFFUSION      n mean   sd
##   <ord>      <dbl> <dbl> <dbl>
## 1 FT_comp      39 1.15  1.01
## 2 FT_sif      43 0.884 1.33
## 3 FT_gaz      36 1.14  1.29
## 4 FJ          37 0.784 1.08
## 5 FG          26 0.615 0.941
## 6 MC          24 0.417 0.929
```

On modélise encore ces données avec un modèle binomial négatif.

## Comparaison de nos données au modèle fitté



Encore une fois, ce modèle fait de bonnes prédictions. Regardons les résultats qu'il nous donne :

```
## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: Negative Binomial(2.0449) ( log )
## Formula: SURVOLS ~ DIFFUSION + (1 | ID_MALE)
## Data: data_reponse
##
##      AIC      BIC   logLik deviance df.resid
##    533.5    560.0   -258.7   517.5     197
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -0.8930 -0.7450 -0.5530  0.4125  4.6218
##
## Random effects:
## Groups Name          Variance Std.Dev.
## ID_MALE (Intercept) 0.0332    0.1822
## Number of obs: 205, groups: ID_MALE, 11
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.26588    0.12098  -2.198   0.0280 *
## DIFFUSION.L -0.77315    0.26933  -2.871   0.0041 **
## DIFFUSION.Q -0.28600    0.25358  -1.128   0.2594
## DIFFUSION.C -0.08672    0.24925  -0.348   0.7279
## DIFFUSION^4  0.16404    0.23808   0.689   0.4908
```

```

## DIFFUSION^5 -0.20776    0.21873  -0.950   0.3422
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##           (Intr) DIFFUSION.L DIFFUSION.Q DIFFUSION.C DIFFUSION^4
## DIFFUSION.L  0.339
## DIFFUSION.Q  0.189  0.374
## DIFFUSION.C  0.047  0.135    0.334
## DIFFUSION^4 -0.033  0.017    0.154    0.301
## DIFFUSION^5  0.032 -0.024    0.035    0.136    0.211

## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.

## Marginal Contrasts Analysis
##
## Level1 | Level2 | Difference |          95% CI |    SE | df |          z |          p | p.signif
## -----|-----|-----|-----|-----|----|-----|-----|-----|
## FG      | MC      | 0.40 | [-0.92, 1.73] | 0.45 | Inf | 0.90 | 0.462 | ns
## FJ      | FG      | 0.22 | [-0.84, 1.28] | 0.36 | Inf | 0.60 | 0.632 | ns
## FJ      | MC      | 0.62 | [-0.58, 1.83] | 0.41 | Inf | 1.51 | 0.325 | ns
## FT_comp | FG      | 0.61 | [-0.40, 1.62] | 0.34 | Inf | 1.78 | 0.233 | ns
## FT_comp | FJ      | 0.39 | [-0.46, 1.24] | 0.29 | Inf | 1.36 | 0.341 | ns
## FT_comp | FT_gaz  | -1.82e-03 | [-0.80, 0.80] | 0.27 | Inf | -6.68e-03 | 0.995 | ns
## FT_comp | FT_sif  | 0.28 | [-0.52, 1.08] | 0.27 | Inf | 1.02 | 0.462 | ns
## FT_comp | MC      | 1.01 | [-0.14, 2.17] | 0.40 | Inf | 2.57 | 0.082 | ns
## FT_gaz  | FG      | 0.61 | [-0.41, 1.63] | 0.35 | Inf | 1.76 | 0.233 | ns
## FT_gaz  | FJ      | 0.39 | [-0.47, 1.26] | 0.30 | Inf | 1.33 | 0.341 | ns
## FT_gaz  | MC      | 1.02 | [-0.16, 2.19] | 0.40 | Inf | 2.55 | 0.082 | ns
## FT_sif  | FG      | 0.33 | [-0.69, 1.36] | 0.35 | Inf | 0.96 | 0.462 | ns
## FT_sif  | FJ      | 0.12 | [-0.75, 0.98] | 0.29 | Inf | 0.39 | 0.744 | ns
## FT_sif  | FT_gaz  | -0.28 | [-1.10, 0.54] | 0.28 | Inf | -1.00 | 0.462 | ns
## FT_sif  | MC      | 0.74 | [-0.43, 1.91] | 0.40 | Inf | 1.85 | 0.233 | ns
##
## Marginal contrasts estimated at DIFFUSION
## p-value adjustment method: Benjamini & Hochberg (1995)

Encore une fois, nous n'avons pas de différence détectée par notre modèle, bien que les tests paramétriques nous fassent conclure à des différences.

##
## Kruskal-Wallis rank sum test
##
## data:  SURVOLS by DIFFUSION
## Kruskal-Wallis chi-squared = 23.739, df = 5, p-value = 0.0002436


## # A tibble: 15 x 9
##   .y.      group1 group2    n1    n2 statistic      p    p.adj p.adj.signif
##   * <chr>   <chr>   <chr> <int> <int>   <dbl>   <dbl>   <dbl>   <chr>
## 1 SURVOLS FT_comp FT_sif    65    63    -1.28  0.202    0.276    ns
## 2 SURVOLS FT_comp FT_gaz    65    63    -0.574 0.566    0.566    ns
## 3 SURVOLS FT_comp FJ        65    63    -1.92  0.0542    0.102    ns
## 4 SURVOLS FT_comp FG        65    63    -3.30  0.000967  0.00483 **
## 5 SURVOLS FT_comp MC        65    60    -3.96  0.0000736 0.00110 **
## 6 SURVOLS FT_sif FT_gaz    63    63     0.696 0.486    0.556    ns
## 7 SURVOLS FT_sif FJ        63    63    -0.645 0.519    0.556    ns

```

##	8	SURVOLS	FT_sif	FG	63	63	-2.01	0.0445	0.0954	ns
##	9	SURVOLS	FT_sif	MC	63	60	-2.68	0.00726	0.0218	*
##	10	SURVOLS	FT_gaz	FJ	63	63	-1.34	0.180	0.270	ns
##	11	SURVOLS	FT_gaz	FG	63	63	-2.71	0.00682	0.0218	*
##	12	SURVOLS	FT_gaz	MC	63	60	-3.37	0.000746	0.00483	**
##	13	SURVOLS	FJ	FG	63	63	-1.36	0.172	0.270	ns
##	14	SURVOLS	FJ	MC	63	60	-2.05	0.0406	0.0954	ns
##	15	SURVOLS	FG	MC	63	60	-0.700	0.484	0.556	ns


Avec ces derniers tests, le nombre de survols est significativement plus important quand nous passons le chant complet ou les gazouillis de fauvette à tête noire par rapport à celui de la fauvette grisette et de la mésange charbonnière. Nous retrouvons également un résultat similaire entre les sifflements de fauvette à tête noire et le chant de la mésange charbonnière. En revanche, pour ce dernier, si nous nous rapportons au tableau de statistiques descriptives, nous remarquons que la différence entre les deux groupes est de moins de 0.2 survols, ce qui semble être un effet négligeable (sans compter que les deux groupes ont la même médiane qui est... nulle).

Nombre de survols selon le type de diffusion



**4. Effet de la diffusion sur la distance d’approche minimale** Nous voici maintenant à notre avant dernière variable de réponse : la distance minimale d’approche. Avec les survols, elles sont qualifiées dans plusieurs articles de “high-risk defense behaviour” contrairement au chant et aux cris qui sont des “low-risk defense behaviour”. Cela est dû au fait qu’il est plus coûteux et que l’oiseau se met plus en danger en approchant un intrus, rendant plus plausible un affrontement physique direct. Tout d’abord, représentons nos données. Pour représenter nos données, nous utiliserons cette fois-ci un graphique en tuyaux d’orgues car nous avons relevé la distance minimale comme une variable qualitative ordinale.

## Distances minimales d'approche selon la diffusion passée



Sur ce graphique, il semble que les 3 panels supérieurs se ressemblent beaucoup (ce sont ceux de la diffusion de bande son de fauvette à tête noire). Les trois autres ont nettement moins, en nombre et en proportion, d'oiseaux se rapprochant à moins de 10 mètres.


Pour tester les différences entre les groupes, comme c'est une variable qualitative ordinale, nous utilisons un test non paramétrique : l'ANOVA de Kruskal-Wallis suivie d'un test de Dunn.

```
##
## Kruskal-Wallis rank sum test
##
## data:  DISTANCE_MIN_FACTOR by DIFFUSION
## Kruskal-Wallis chi-squared = 15.382, df = 5, p-value = 0.008849

## # A tibble: 15 x 8
##   group1 group2  n1  n2 statistic      p p.adj p.adj.signif
##   <chr>   <chr> <int> <int>   <dbl>   <dbl>   <dbl>   <chr>
## 1 FT_comp FT_sif    39   43     0.418 0.676   0.845   ns
## 2 FT_comp FT_gaz    39   36     0.249 0.803   0.861   ns
## 3 FT_comp FJ        39   37     1.45  0.148   0.278   ns
## 4 FT_comp FG        39   26     2.63  0.00847 0.0405  *
## 5 FT_comp MC        39   24     2.86  0.00424 0.0405  *
## 6 FT_sif  FT_gaz    43   36    -0.155 0.877   0.877   ns
## 7 FT_sif  FJ        43   37     1.07  0.285   0.389   ns
## 8 FT_sif  FG        43   26     2.31  0.0208  0.0521  ns
## 9 FT_sif  MC        43   24     2.55  0.0108  0.0405  *
## 10 FT_gaz FJ        36   37     1.17  0.241   0.362   ns
## 11 FT_gaz FG        36   26     2.37  0.0180  0.0521  ns
## 12 FT_gaz MC        36   24     2.60  0.00941 0.0405  *
```

## 13 FJ	FG	37	26	1.31	0.191	0.318	ns
## 14 FJ	MC	37	24	1.56	0.118	0.253	ns
## 15 FG	MC	26	24	0.266	0.790	0.861	ns

Ainsi, nous obtenons des différences significative (en terme de médiane) entre : - FT\_comp et FG - FT\_comp et MC - FT\_sif et MC - FT\_gaz et MC Avec pour chacune de ces différence, le chant cité en premier lié au rapprochement le plus important de l'oiseau. Cela va donc bien dans le sens que les fauvettes ont un comportement plus virulent face à leur congénère, confirmant ce que rapporte la littérature à ce sujet.



## 5. Effet de la diffusion sur le temps de latence avant la réponse

Nous voyons peut-être une légère tendance sur ces boxplots (réactions à gauches plus lentes qu'à droite), mais cela est très incertain. Nous devons réaliser les tests pour nous en convaincre.

Nous avons choisi le modèle avec la même méthode que tout à l'heure.

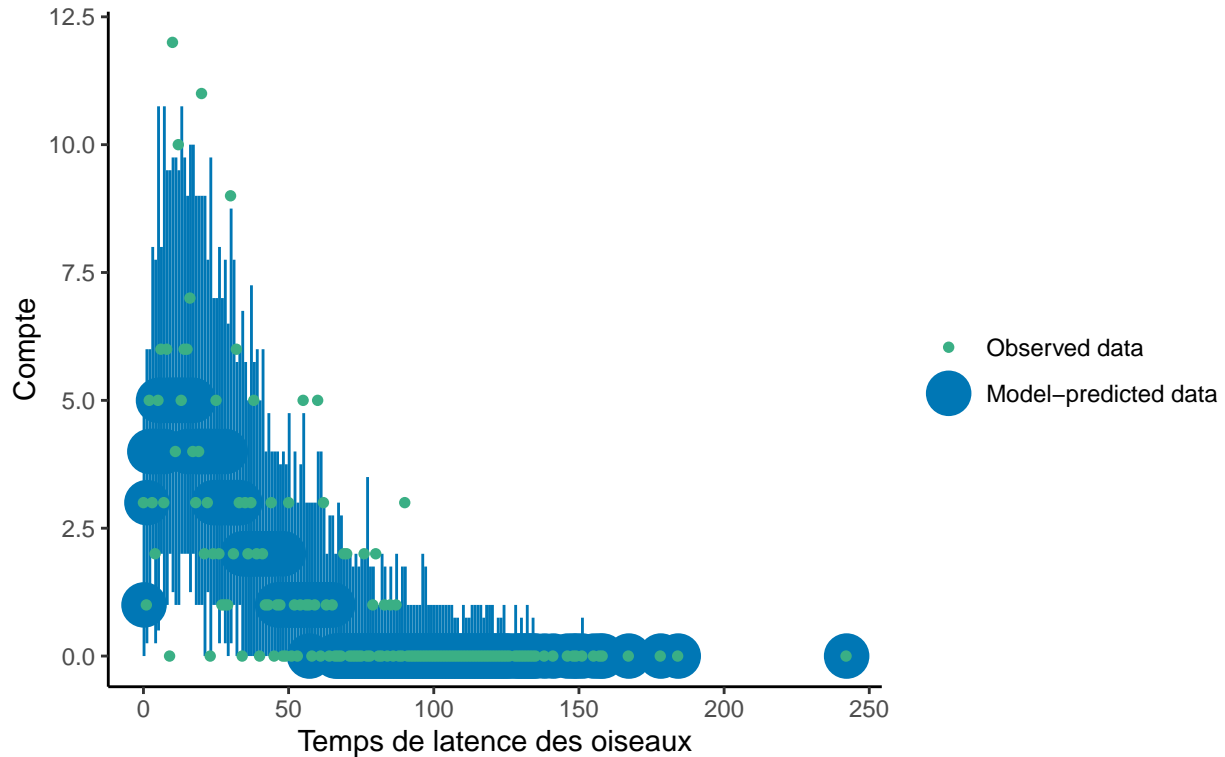
```
mod_latence_bn <- MASS::glm.nb(
  LATENCE ~ DIFFUSION, data = data_reponse
)

mod_latence_bn |>
  performance::check_predictions() |>
  plot() +
  labs(
    title="Comparaison de nos données au modèle fitté",
    subtitle="",
    x="Temps de latence des oiseaux",
    y="Compte"
  ) +
```



```
theme_classic()
```

## Comparaison de nos données au modèle fitté



Etant donné que le (meilleur) modèle donne des résultats très peu satisfaisants en terme de prédiction, nous préférons ne pas l'utiliser et directement faire des tests non paramétriques.

```
##
##  Kruskal-Wallis rank sum test
##
## data:  LATENCE by DIFFUSION
## Kruskal-Wallis chi-squared = 2.7332, df = 5, p-value = 0.741
## # A tibble: 15 x 8
##   group1 group2  n1  n2 statistic    p p.adj p.adj.signif
##   <chr>  <chr> <int> <int>    <dbl> <dbl> <dbl> <chr>
## 1 FT_comp FT_sif   39   43  -0.301  0.763  0.881 ns
## 2 FT_comp FT_gaz   39   36  -1.29   0.198  0.881 ns
## 3 FT_comp FJ       39   37  -0.633  0.527  0.881 ns
## 4 FT_comp FG       39   26  -0.777  0.437  0.881 ns
## 5 FT_comp MC       39   24  -1.25   0.213  0.881 ns
## 6 FT_sif  FT_gaz   43   36  -1.02   0.306  0.881 ns
## 7 FT_sif  FJ       43   37  -0.351  0.726  0.881 ns
## 8 FT_sif  FG       43   26  -0.524  0.600  0.881 ns
## 9 FT_sif  MC       43   24  -1.01   0.314  0.881 ns
## 10 FT_gaz FJ       36   37   0.651  0.515  0.881 ns
## 11 FT_gaz FG       36   26   0.392  0.695  0.881 ns
## 12 FT_gaz MC       36   24  -0.0969 0.923  0.923 ns
## 13 FJ     FG       37   26  -0.201  0.840  0.900 ns
```

## 14 FJ	MC	37	24	-0.679	0.497	0.881	ns
## 15 FG	MC	26	24	-0.447	0.655	0.881	ns

En terme de moyenne du temps de latence, nous avons donc :  $FT_{sif} > FT_{comp} > FG > FJ > FT_{gaz} > MC$   
Parmis ces comparaisons, aucune n'est significative.

**6. Interprétation des résultats de la section II.B.** La section 1. nous a montré que les réponses de type chant existaient pour les 3 diffusions de fauvette à tête noire et pour la fauvette des jardin. Ce type de réponse était d'ailleurs plus important pour le chant complet de fauvette à tête noire. Ainsi, cela pourrait traduire le fait que le chant est une réponse orientée vers l'intrusion d'individus conspécifiques car étant un caractère sexuel des mâles.

Ensuite, pour ce qui est de la réponse de type cris, la tendance s'inversait et la réponse était plus forte pour les espèces éloignées phylogénétiquement des oiseaux étudiés. En effet, les réponses les plus fortes étaient retrouvées chez les mésanges charonières et les fauvettes grisette. . . Cela peut être à la fois dû au fait que lors de la diffusion des chants conspécifiques, les oiseaux répondaient en chantant et ne criaient pas en même temps. On pourrait alors interpréter les cris comme une réponse non spécifique à une perturbation. Cela peut également remettre en cause l'utilisation de la mésange charbonnière comme témoin négatif puisque le chant de ces dernières suscitait de fortes réactions de type cris.


En ce qui concerne les réponses physiques (survol et approche), les réponses les plus fortes étaient retrouvées pour les enregistrements de fauvette à tête noire.

### III. Facteurs confondants

#### A. Effet de la réaction de la femelle sur la réponse du mâle


On s'intéresse maintenant à l'effet de la réponse des femelle sur celle des mâles.

**1. Association entre la “réponse binaire” et la réaction de la femelle** Tout d'abord, il est important de noter que la femelle était détectée principalement en présence du mâle.



Ainsi, nous avons  $\mathbb{P}_{réponse}(Femelle) = 25\%$ , alors que  $\mathbb{P}_{non-réponse}(Femelle) = 8\%$ .

## Réaction des femelles selon la réaction des mâles



```
glmer(
  FEMELLE~ DIFFUSION + (LATENCE_BINAIRE|ID_MALE),
  data = data, family = binomial
) |> estimate_contrasts(p_adjust="fdr") |>
  add_significance()
```

```
## Warning in checkConv(attr(opt, "derivs"), opt$par, ctrl = control$checkConv, :
## Model failed to converge with max|grad| = 0.00219269 (tol = 0.002, component 1)

## No variable was specified for contrast estimation. Selecting `contrast = "DIFFUSION"`.
```

```
## Marginal Contrasts Analysis
```

```
##
## Level1 | Level2 | Difference |          95% CI | SE | df | z | p | p.signif
## -----|-----|-----|-----|-----|-----|-----|-----|-----|-----
## FG      | MC      | -0.64 | [-2.60, 1.33] | 0.67 | Inf | -0.95 | 0.486 | ns
## FJ      | FG      | 0.98 | [-0.86, 2.82] | 0.63 | Inf | 1.56 | 0.221 | ns
## FJ      | MC      | 0.35 | [-1.24, 1.93] | 0.54 | Inf | 0.64 | 0.602 | ns
## FT_comp | FG      | 0.60 | [-1.31, 2.50] | 0.65 | Inf | 0.92 | 0.486 | ns
## FT_comp | FJ      | -0.38 | [-1.89, 1.12] | 0.51 | Inf | -0.75 | 0.570 | ns
## FT_comp | FT_gaz  | -0.98 | [-2.41, 0.44] | 0.49 | Inf | -2.02 | 0.129 | ns
## FT_comp | FT_sif  | -1.17 | [-2.60, 0.26] | 0.49 | Inf | -2.40 | 0.083 | ns
## FT_comp | MC      | -0.04 | [-1.69, 1.62] | 0.56 | Inf | -0.07 | 0.948 | ns
## FT_gaz  | FG      | 1.58 | [-0.19, 3.36] | 0.60 | Inf | 2.62 | 0.066 | ns
## FT_gaz  | FJ      | 0.60 | [-0.74, 1.95] | 0.46 | Inf | 1.31 | 0.315 | ns
## FT_gaz  | MC      | 0.95 | [-0.55, 2.45] | 0.51 | Inf | 1.85 | 0.160 | ns
## FT_sif  | FG      | 1.77 | [ 0.00, 3.54] | 0.60 | Inf | 2.93 | 0.050 | ns
```

```
## FT_sif | FJ | 0.79 | [-0.55, 2.13] | 0.46 | Inf | 1.72 | 0.182 | ns
## FT_sif | FT_gaz | 0.19 | [-1.05, 1.42] | 0.42 | Inf | 0.44 | 0.708 | ns
## FT_sif | MC | 1.13 | [-0.37, 2.64] | 0.51 | Inf | 2.21 | 0.101 | ns
##
## Marginal contrasts estimated at DIFFUSION
## p-value adjustment method: Benjamini & Hochberg (1995)
```


Les femelles ne semblent pas réagir différemment selon le type de diffusion lorsque l'on corrige pour l'effet de la réponse des mâles. Ainsi, les différences que nous pouvions observer sur les précédents graphiques proviendraient seulement de la réactivité des mâles. Les femelles réagiraient principalement quand les mâles réagissent eux même.

On regarde maintenant l'intensité de la réponse du mâle selon qu'il y ait ou non réaction de la femelle.

## 2. Association de la réaction de la femelle sur le nombre de cris

```
## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: Negative Binomial(0.2442) ( log )
## Formula: CRIS ~ as.factor(FEMELLE) + DIFFUSION + (1 | ID_MALE)
## Data: data_reponse
##
##      AIC      BIC    logLik deviance df.resid
## 1299.5    1329.4   -640.8   1281.5      196
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -0.4932 -0.4807 -0.4230  0.1081  5.1193
##
## Random effects:
##  Groups Name      Variance Std.Dev.
##  ID_MALE (Intercept) 1.261    1.123
## Number of obs: 205, groups: ID_MALE, 11
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)      2.33826    0.38690   6.044 1.51e-09 ***
## as.factor(FEMELLE)1  0.11296    0.38148   0.296   0.767
## DIFFUSION.L        0.47629    0.42813   1.112   0.266
## DIFFUSION.Q        0.34040    0.42313   0.804   0.421
## DIFFUSION.C        0.19981    0.41698   0.479   0.632
## DIFFUSION^4       -0.37290    0.37719  -0.989   0.323
## DIFFUSION^5       -0.01023    0.39244  -0.026   0.979
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) a.(FEM DIFFUSION.L DIFFUSION.Q DIFFUSION.C DIFFUSION^4
## a.(FEMELLE) -0.237
## DIFFUSION.L  0.113 -0.070
## DIFFUSION.Q -0.009  0.095  0.153
## DIFFUSION.C -0.007 -0.125  0.050   0.197
## DIFFUSION^4  0.043 -0.135  0.058   0.048   0.142
## DIFFUSION^5 -0.022  0.123 -0.007   0.001  -0.074  -0.006
```

```
ggboxplot(data_reponse, x="FEMELLE", y="CRIS", fill="cyan2") +
  facet_wrap(~DIFFUSION) + geom_jitter(width=0.2, color="cyan4") +
  theme_minimal() +
  labs(
    title="Nombre de cris selon le type de diffusion",
    x="Réaction d'une femelle", y="Nombre de cris"
  )
```



Cela ne donne aucun résultat significatif et il faut se méfier du boxplot ci-dessus qui pourrait nous laisser penser à de petites tendances pour certaines espèces (MC, FG) mais cela n'est du qu'au faible nombre de données.

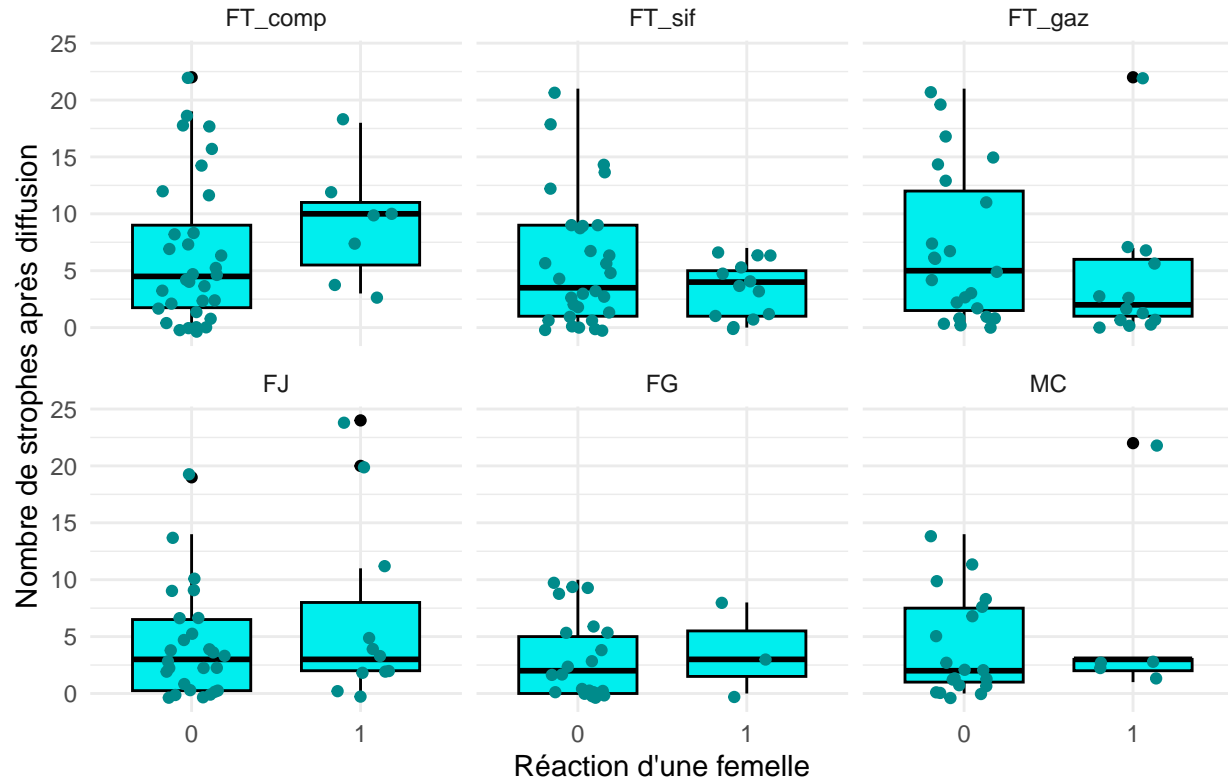
### 3. Association de la réaction de la femelle sur la réaction de type chant

```
## Generalized linear mixed model fit by maximum likelihood (Laplace
## Approximation) [glmerMod]
## Family: Negative Binomial(1.0068) ( log )
## Formula: STROPHESES_APRES ~ as.factor(FEMELLE) + DIFFUSION + (1 | ID_MALE)
## Data: data_reponse
##
##      AIC      BIC    logLik deviance df.resid
##  1120.2   1150.1   -551.1   1102.2     196
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -0.9449 -0.7074 -0.2903  0.3791  3.6827
```

```
##
## Random effects:
## Groups Name Variance Std.Dev.
## ID_MALE (Intercept) 0.1449 0.3807
## Number of obs: 205, groups: ID_MALE, 11
##
## Fixed effects:
## Estimate Std. Error z value Pr(>|z|)
## (Intercept) 1.42986 0.15309 9.340 <2e-16 ***
## as.factor(FEMELLE)1 0.06607 0.18568 0.356 0.7220
## DIFFUSION.L -0.53734 0.20571 -2.612 0.0090 **
## DIFFUSION.Q 0.06457 0.20046 0.322 0.7474
## DIFFUSION.C 0.11462 0.19978 0.574 0.5662
## DIFFUSION^4 0.40463 0.20027 2.020 0.0433 *
## DIFFUSION^5 -0.02979 0.19320 -0.154 0.8775
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
## (Intr) a.(FEM DIFFUSION.L DIFFUSION.Q DIFFUSION.C DIFFUSION^4
## a.(FEMELLE) -0.306
## DIFFUSION.L 0.135 -0.008
## DIFFUSION.Q 0.034 0.061 0.145
## DIFFUSION.C 0.005 -0.044 0.004 0.131
## DIFFUSION^4 0.017 -0.093 -0.089 0.061 0.237
## DIFFUSION^5 0.026 -0.094 0.002 0.042 0.082 0.115

ggboxplot(data_reponse, x="FEMELLE", y="STROPHES_APRES", fill="cyan2") +
  facet_wrap(~DIFFUSION) + geom_jitter(width=0.2, color="cyan4") +
  theme_minimal() +
  labs(
    title="Nombre de cris selon le type de diffusion",
    x="Réaction d'une femelle",
    y="Nombre de strophes après diffusion"
  )
```

## Nombre de cris selon le type de diffusion



Encore une fois, aucun résultat.

### 4. Association de la réaction de la femelle sur le nombre de survols

```
##
## Call:
## MASS::glm.nb(formula = SURVOLS ~ as.factor(FEMELLE) + DIFFUSION,
##   data = data_reponse, init.theta = 2.411727764, link = log)
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.4185    0.1165  -3.591 0.000329 ***
## as.factor(FEMELLE)1    0.5882    0.1906   3.086 0.002031 **
## DIFFUSION.L    -0.7380    0.2644  -2.791 0.005248 **
## DIFFUSION.Q    -0.1915    0.2504  -0.765 0.444308
## DIFFUSION.C    -0.1648    0.2464  -0.669 0.503521
## DIFFUSION^4     0.1060    0.2341   0.453 0.650780
## DIFFUSION^5    -0.1994    0.2125  -0.939 0.347904
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(2.4117) family taken to be 1)
##
## Null deviance: 231.93  on 204  degrees of freedom
## Residual deviance: 210.95  on 198  degrees of freedom
## AIC: 524.9
##
```



## Number of Fisher Scoring iterations: 1

##

##

##           Theta: 2.41

##           Std. Err.: 1.04

##

## 2 x log-likelihood: -508.898

## Marginal Contrasts Analysis

##

## Level1	Level2	Difference	95% CI	SE	df	z	p
## FG FEMELLE0	FG FEMELLE1	-0.59	[-1.23, 0.05]	0.19	Inf	-3.09	0.015
## FG FEMELLE0	FJ FEMELLE1	-0.70	[-1.99, 0.59]	0.38	Inf	-1.83	0.178
## FG FEMELLE0	FT_comp FEMELLE1	-1.17	[-2.45, 0.10]	0.38	Inf	-3.10	0.015
## FG FEMELLE0	FT_gaz FEMELLE1	-1.03	[-2.27, 0.20]	0.37	Inf	-2.81	0.027
## FG FEMELLE0	FT_sif FEMELLE1	-0.82	[-2.07, 0.43]	0.37	Inf	-2.21	0.085
## FG FEMELLE0	MC FEMELLE0	0.44	[-1.05, 1.94]	0.44	Inf	1.00	0.454
## FG FEMELLE0	MC FEMELLE1	-0.14	[-1.74, 1.45]	0.47	Inf	-0.30	0.798
## FG FEMELLE1	MC FEMELLE1	0.44	[-1.05, 1.94]	0.44	Inf	1.00	0.454
## FJ FEMELLE0	FG FEMELLE0	0.11	[-1.09, 1.32]	0.36	Inf	0.32	0.798
## FJ FEMELLE0	FG FEMELLE1	-0.47	[-1.90, 0.96]	0.42	Inf	-1.12	0.407
## FJ FEMELLE0	FJ FEMELLE1	-0.59	[-1.23, 0.05]	0.19	Inf	-3.09	0.015
## FJ FEMELLE0	FT_comp FEMELLE1	-1.06	[-2.27, 0.15]	0.36	Inf	-2.96	0.019
## FJ FEMELLE0	FT_gaz FEMELLE1	-0.92	[-2.06, 0.23]	0.34	Inf	-2.70	0.032
## FJ FEMELLE0	FT_sif FEMELLE1	-0.71	[-1.87, 0.46]	0.35	Inf	-2.04	0.113
## FJ FEMELLE0	MC FEMELLE0	0.56	[-0.81, 1.92]	0.40	Inf	1.38	0.326
## FJ FEMELLE0	MC FEMELLE1	-0.03	[-1.56, 1.50]	0.46	Inf	-0.07	0.962
## FJ FEMELLE1	FG FEMELLE1	0.11	[-1.09, 1.32]	0.36	Inf	0.32	0.798
## FJ FEMELLE1	MC FEMELLE1	0.56	[-0.81, 1.92]	0.40	Inf	1.38	0.326
## FT_comp FEMELLE0	FG FEMELLE0	0.59	[-0.54, 1.72]	0.34	Inf	1.75	0.194
## FT_comp FEMELLE0	FG FEMELLE1	-2.62e-03	[-1.32, 1.32]	0.39	Inf	-6.67e-03	0.995
## FT_comp FEMELLE0	FJ FEMELLE0	0.47	[-0.48, 1.43]	0.28	Inf	1.66	0.206
## FT_comp FEMELLE0	FJ FEMELLE1	-0.12	[-1.21, 0.98]	0.33	Inf	-0.36	0.798
## FT_comp FEMELLE0	FT_comp FEMELLE1	-0.59	[-1.23, 0.05]	0.19	Inf	-3.09	0.015
## FT_comp FEMELLE0	FT_gaz FEMELLE0	0.14	[-0.76, 1.04]	0.27	Inf	0.53	0.702
## FT_comp FEMELLE0	FT_gaz FEMELLE1	-0.45	[-1.47, 0.58]	0.30	Inf	-1.47	0.294
## FT_comp FEMELLE0	FT_sif FEMELLE0	0.35	[-0.54, 1.25]	0.27	Inf	1.33	0.327
## FT_comp FEMELLE0	FT_sif FEMELLE1	-0.23	[-1.28, 0.81]	0.31	Inf	-0.76	0.593
## FT_comp FEMELLE0	MC FEMELLE0	1.03	[-0.28, 2.34]	0.39	Inf	2.65	0.033
## FT_comp FEMELLE0	MC FEMELLE1	0.44	[-1.00, 1.88]	0.43	Inf	1.03	0.452
## FT_comp FEMELLE1	FG FEMELLE1	0.59	[-0.54, 1.72]	0.34	Inf	1.75	0.194
## FT_comp FEMELLE1	FJ FEMELLE1	0.47	[-0.48, 1.43]	0.28	Inf	1.66	0.206
## FT_comp FEMELLE1	FT_gaz FEMELLE1	0.14	[-0.76, 1.04]	0.27	Inf	0.53	0.702
## FT_comp FEMELLE1	FT_sif FEMELLE1	0.35	[-0.54, 1.25]	0.27	Inf	1.33	0.327
## FT_comp FEMELLE1	MC FEMELLE1	1.03	[-0.28, 2.34]	0.39	Inf	2.65	0.033
## FT_gaz FEMELLE0	FG FEMELLE0	0.44	[-0.72, 1.60]	0.34	Inf	1.29	0.336
## FT_gaz FEMELLE0	FG FEMELLE1	-0.14	[-1.56, 1.27]	0.42	Inf	-0.35	0.798
## FT_gaz FEMELLE0	FJ FEMELLE0	0.33	[-0.64, 1.30]	0.29	Inf	1.14	0.407
## FT_gaz FEMELLE0	FJ FEMELLE1	-0.26	[-1.45, 0.93]	0.35	Inf	-0.73	0.599
## FT_gaz FEMELLE0	FT_comp FEMELLE1	-0.73	[-1.91, 0.45]	0.35	Inf	-2.08	0.108
## FT_gaz FEMELLE0	FT_gaz FEMELLE1	-0.59	[-1.23, 0.05]	0.19	Inf	-3.09	0.015
## FT_gaz FEMELLE0	FT_sif FEMELLE1	-0.38	[-1.51, 0.76]	0.34	Inf	-1.11	0.407
## FT_gaz FEMELLE0	MC FEMELLE0	0.89	[-0.44, 2.21]	0.39	Inf	2.26	0.079

## FT_gaz FEMELLE0	MC FEMELLE1	0.30	[-1.22, 1.82]	0.45	Inf	0.67	0.618
## FT_gaz FEMELLE1	FG FEMELLE1	0.44	[-0.72, 1.60]	0.34	Inf	1.29	0.336
## FT_gaz FEMELLE1	FJ FEMELLE1	0.33	[-0.64, 1.30]	0.29	Inf	1.14	0.407
## FT_gaz FEMELLE1	MC FEMELLE1	0.89	[-0.44, 2.21]	0.39	Inf	2.26	0.079
## FT_sif FEMELLE0	FG FEMELLE0	0.23	[-0.92, 1.39]	0.34	Inf	0.68	0.618
## FT_sif FEMELLE0	FG FEMELLE1	-0.36	[-1.75, 1.03]	0.41	Inf	-0.86	0.545
## FT_sif FEMELLE0	FJ FEMELLE0	0.12	[-0.85, 1.09]	0.29	Inf	0.41	0.777
## FT_sif FEMELLE0	FJ FEMELLE1	-0.47	[-1.64, 0.69]	0.35	Inf	-1.36	0.327
## FT_sif FEMELLE0	FT_comp FEMELLE1	-0.94	[-2.10, 0.22]	0.34	Inf	-2.74	0.031
## FT_sif FEMELLE0	FT_gaz FEMELLE0	-0.21	[-1.12, 0.70]	0.27	Inf	-0.78	0.585
## FT_sif FEMELLE0	FT_gaz FEMELLE1	-0.80	[-1.89, 0.29]	0.32	Inf	-2.46	0.051
## FT_sif FEMELLE0	FT_sif FEMELLE1	-0.59	[-1.23, 0.05]	0.19	Inf	-3.09	0.015
## FT_sif FEMELLE0	MC FEMELLE0	0.68	[-0.65, 2.00]	0.39	Inf	1.72	0.194
## FT_sif FEMELLE0	MC FEMELLE1	0.09	[-1.41, 1.58]	0.44	Inf	0.20	0.870
## FT_sif FEMELLE1	FG FEMELLE1	0.23	[-0.92, 1.39]	0.34	Inf	0.68	0.618
## FT_sif FEMELLE1	FJ FEMELLE1	0.12	[-0.85, 1.09]	0.29	Inf	0.41	0.777
## FT_sif FEMELLE1	FT_gaz FEMELLE1	-0.21	[-1.12, 0.70]	0.27	Inf	-0.78	0.585
## FT_sif FEMELLE1	MC FEMELLE1	0.68	[-0.65, 2.00]	0.39	Inf	1.72	0.194
## MC FEMELLE0	FG FEMELLE1	-1.03	[-2.69, 0.63]	0.49	Inf	-2.10	0.108
## MC FEMELLE0	FJ FEMELLE1	-1.15	[-2.63, 0.33]	0.44	Inf	-2.61	0.035
## MC FEMELLE0	FT_comp FEMELLE1	-1.62	[-3.09, -0.15]	0.44	Inf	-3.70	0.014
## MC FEMELLE0	FT_gaz FEMELLE1	-1.48	[-2.90, -0.05]	0.42	Inf	-3.48	0.015
## MC FEMELLE0	FT_sif FEMELLE1	-1.26	[-2.71, 0.18]	0.43	Inf	-2.95	0.019
## MC FEMELLE0	MC FEMELLE1	-0.59	[-1.23, 0.05]	0.19	Inf	-3.09	0.015

##

## Marginal contrasts estimated at DIFFUSION, FEMELLE

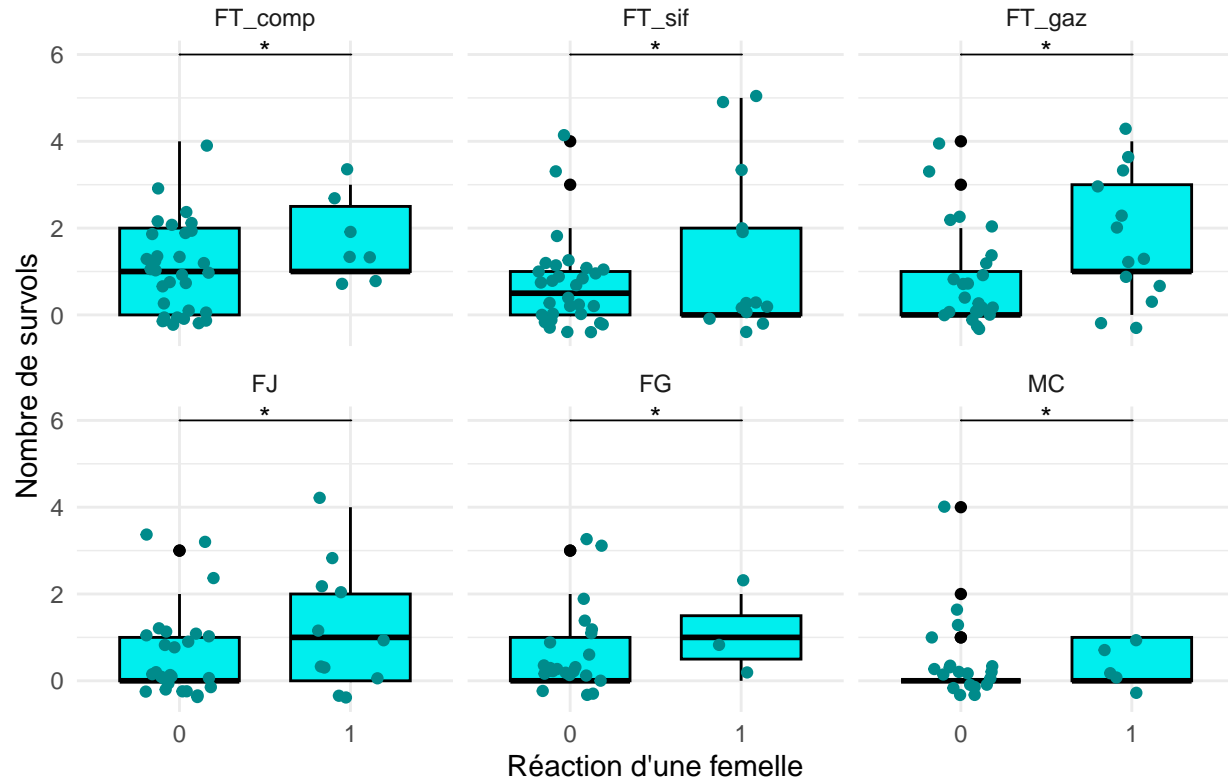
## p-value adjustment method: Benjamini & Hochberg (1995)

Ici, on a une significativement plus de survols lorsque la femelle est présente quelque soit la diffusion passée (pour une diffusion donnée, on ne compare que avec et sans femelle) !

```
stat_femelle_surv <- stat_result_paired |>
  mutate(
    .y="SURVOLS", group1=0, group2=1, y.position=6,
    p.adj.signif="*", groups=list(c(0,1), c(0,1), c(0,1), c(0,1), c(0,1), c(0,1))
  ) |>
  select(-c(n1, n2, statistic, p, p.adj, df))

ggboxplot(data_reponse, x="FEMELLE", y="SURVOLS", fill="cyan2") +
  facet_wrap(~DIFFUSION) + geom_jitter(width=0.2, color="cyan4") +
  theme_minimal() +
  labs(
    title="Nombre de cris selon le type de diffusion",
    x="Réaction d'une femelle", y="Nombre de survols"
  ) +
  stat_pvalue_manual(stat_femelle_surv, tip.length = 0)
```

## Nombre de cris selon le type de diffusion



## B. Réponse en fonction des jours

Tout d'abord, nous regardons s'il y a des jours où les oiseaux réagissent plus ou moins aux diffusions.

```
table_data_jour <- data |> select(JOUR, ANNEE, LATENCE_BINAIRE) |> table()
```

```
table_data_count_n <- table_data_jour |> data.frame() |>
  group_by(JOUR, ANNEE) |> mutate(N = sum(Freq)) |>
  filter(LATENCE_BINAIRE == 1) |> select(-LATENCE_BINAIRE) |>
  rename(REACTION=Freq)
```

```
table_data_ci <- table_data_count_n |>
  with(binom.confint(REACTION, N, methods="wilson")) |>
  select(x, mean, lower, upper) |>
  rename(REACTION=x, PROP=mean, LOWER=lower, UPPER=upper) |>
  mutate(ANNEE=c(rep(2023,4),rep(2024,4)), JOUR=rep(1:4,2))
```

```
table_final_jour <- merge(
  table_data_count_n, table_data_ci, by=c("JOUR","REACTION", "ANNEE")
)
```

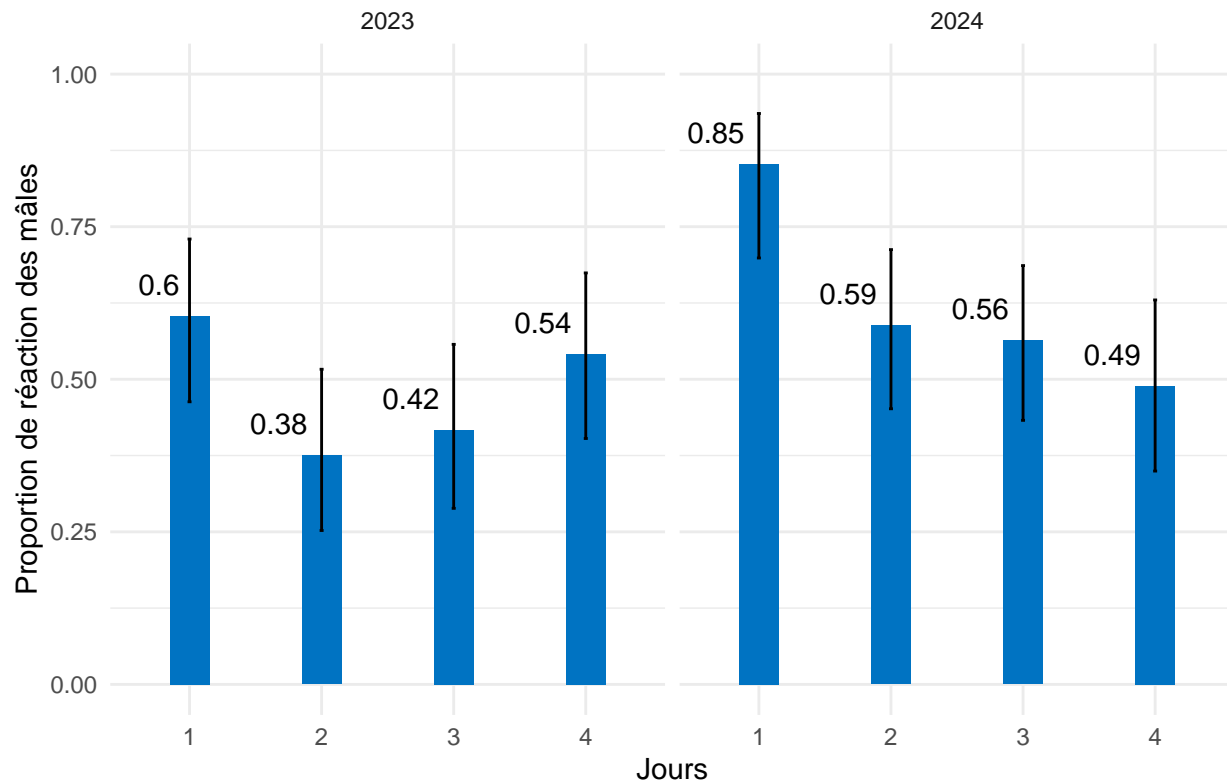
```
ggplot(table_final_jour, aes(x=JOUR, y=PROP)) +
  geom_col(fill = "#0073C2FF", width = 0.3) +
  geom_errorbar(aes(ymin = LOWER, ymax = UPPER), width=0.03) +
  theme_minimal() +
  labs(
```

```

    title="Réaction des mâles selon le jour",
    x="Jours", y="Proportion de réaction des mâles"
  ) +
  geom_text(
    aes(label = round(PROP,2)), hjust=1.25,
    vjust = -1, color = "black"
  ) +
  ylim(0,1) + facet_wrap(~ANNEE)

```

## Réaction des mâles selon le jour



```
rm(table_data_count_n, table_data_ci)
```

On voit sur le graphique qu'en 2024, nous avons plus d'oiseaux répondant le premier jour. En revanche, en 2023, après un premier jour fructueux, ils ont chuté dans les réponses puis sont remontés linéairement. On teste donc cela sachant que les intervalles de confiance semblaient se recouvrir, particulièrement pour l'année 2023.

```
##
## Call:
## glm(formula = LATENCE_BINAIRE ~ JOUR + ANNEE, family = "binomial",
##      data = data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   0.6614     0.2562   2.582  0.00982 **
## JOUR2         -1.0190     0.3199  -3.185  0.00145 **
## JOUR3         -0.9879     0.3178  -3.109  0.00188 **
## JOUR4         -0.8730     0.3232  -2.701  0.00692 **
```

```


## ANNEE2024      0.5738      0.2141      2.681  0.00735 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 519.74  on 376  degrees of freedom
## Residual deviance: 500.62  on 372  degrees of freedom
## AIC: 510.62
##
## Number of Fisher Scoring iterations: 4

## Marginal Contrasts Analysis
##
## Level1          |          Level2 | Difference |          95% CI |    SE |    df |      z |      p | p.sign.
## -----
## JOUR1 ANNEE2023 | JOUR2 ANNEE2023 |      1.02 | [ 0.02, 2.02] | 0.32 | Inf |  3.18 | 0.008 |
## JOUR1 ANNEE2023 | JOUR3 ANNEE2023 |      0.99 | [ 0.00, 1.98] | 0.32 | Inf |  3.11 | 0.008 |
## JOUR1 ANNEE2023 | JOUR4 ANNEE2023 |      0.87 | [-0.14, 1.88] | 0.32 | Inf |  2.70 | 0.016 |
## JOUR1 ANNEE2024 | JOUR1 ANNEE2023 |      0.57 | [-0.09, 1.24] | 0.21 | Inf |  2.68 | 0.016 |
## JOUR1 ANNEE2024 | JOUR2 ANNEE2023 |      1.59 | [ 0.33, 2.86] | 0.40 | Inf |  3.94 | 0.002 |
## JOUR1 ANNEE2024 | JOUR2 ANNEE2024 |      1.02 | [ 0.02, 2.02] | 0.32 | Inf |  3.18 | 0.008 |
## JOUR1 ANNEE2024 | JOUR3 ANNEE2023 |      1.56 | [ 0.30, 2.82] | 0.40 | Inf |  3.86 | 0.002 |
## JOUR1 ANNEE2024 | JOUR3 ANNEE2024 |      0.99 | [ 0.00, 1.98] | 0.32 | Inf |  3.11 | 0.008 |
## JOUR1 ANNEE2024 | JOUR4 ANNEE2023 |      1.45 | [ 0.19, 2.70] | 0.40 | Inf |  3.60 | 0.003 |
## JOUR1 ANNEE2024 | JOUR4 ANNEE2024 |      0.87 | [-0.14, 1.88] | 0.32 | Inf |  2.70 | 0.016 |
## JOUR2 ANNEE2023 | JOUR3 ANNEE2023 |     -0.03 | [-0.92, 0.86] | 0.28 | Inf | -0.11 | 0.913 |
## JOUR2 ANNEE2023 | JOUR4 ANNEE2023 |     -0.15 | [-1.06, 0.77] | 0.29 | Inf | -0.50 | 0.720 |
## JOUR2 ANNEE2024 | JOUR1 ANNEE2023 |     -0.45 | [-1.58, 0.69] | 0.36 | Inf | -1.22 | 0.323 |
## JOUR2 ANNEE2024 | JOUR2 ANNEE2023 |      0.57 | [-0.09, 1.24] | 0.21 | Inf |  2.68 | 0.016 |
## JOUR2 ANNEE2024 | JOUR3 ANNEE2023 |      0.54 | [-0.58, 1.66] | 0.36 | Inf |  1.52 | 0.214 |
## JOUR2 ANNEE2024 | JOUR3 ANNEE2024 |     -0.03 | [-0.92, 0.86] | 0.28 | Inf | -0.11 | 0.913 |
## JOUR2 ANNEE2024 | JOUR4 ANNEE2023 |      0.43 | [-0.69, 1.54] | 0.36 | Inf |  1.20 | 0.323 |
## JOUR2 ANNEE2024 | JOUR4 ANNEE2024 |     -0.15 | [-1.06, 0.77] | 0.29 | Inf | -0.50 | 0.720 |
## JOUR3 ANNEE2023 | JOUR4 ANNEE2023 |     -0.11 | [-1.02, 0.79] | 0.29 | Inf | -0.40 | 0.745 |
## JOUR3 ANNEE2024 | JOUR1 ANNEE2023 |     -0.41 | [-1.54, 0.71] | 0.36 | Inf | -1.15 | 0.335 |
## JOUR3 ANNEE2024 | JOUR2 ANNEE2023 |      0.60 | [-0.50, 1.71] | 0.35 | Inf |  1.71 | 0.153 |
## JOUR3 ANNEE2024 | JOUR3 ANNEE2023 |      0.57 | [-0.09, 1.24] | 0.21 | Inf |  2.68 | 0.016 |
## JOUR3 ANNEE2024 | JOUR4 ANNEE2023 |      0.46 | [-0.64, 1.56] | 0.35 | Inf |  1.30 | 0.300 |
## JOUR3 ANNEE2024 | JOUR4 ANNEE2024 |     -0.11 | [-1.02, 0.79] | 0.29 | Inf | -0.40 | 0.745 |
## JOUR4 ANNEE2024 | JOUR1 ANNEE2023 |     -0.30 | [-1.46, 0.87] | 0.37 | Inf | -0.80 | 0.537 |
## JOUR4 ANNEE2024 | JOUR2 ANNEE2023 |      0.72 | [-0.43, 1.87] | 0.37 | Inf |  1.96 | 0.100 |
## JOUR4 ANNEE2024 | JOUR3 ANNEE2023 |      0.69 | [-0.46, 1.84] | 0.37 | Inf |  1.87 | 0.114 |
## JOUR4 ANNEE2024 | JOUR4 ANNEE2023 |      0.57 | [-0.09, 1.24] | 0.21 | Inf |  2.68 | 0.016 |
##
## Marginal contrasts estimated at JOUR, ANNEE
## p-value adjustment method: Benjamini & Hochberg (1995)


```


Ensuite, on veut tester l'effet du jour sur l'intensité de la réponse, donc on utilise les données des oiseaux ayant répondu.

## Distances minimales d'approche selon la diffusion passée

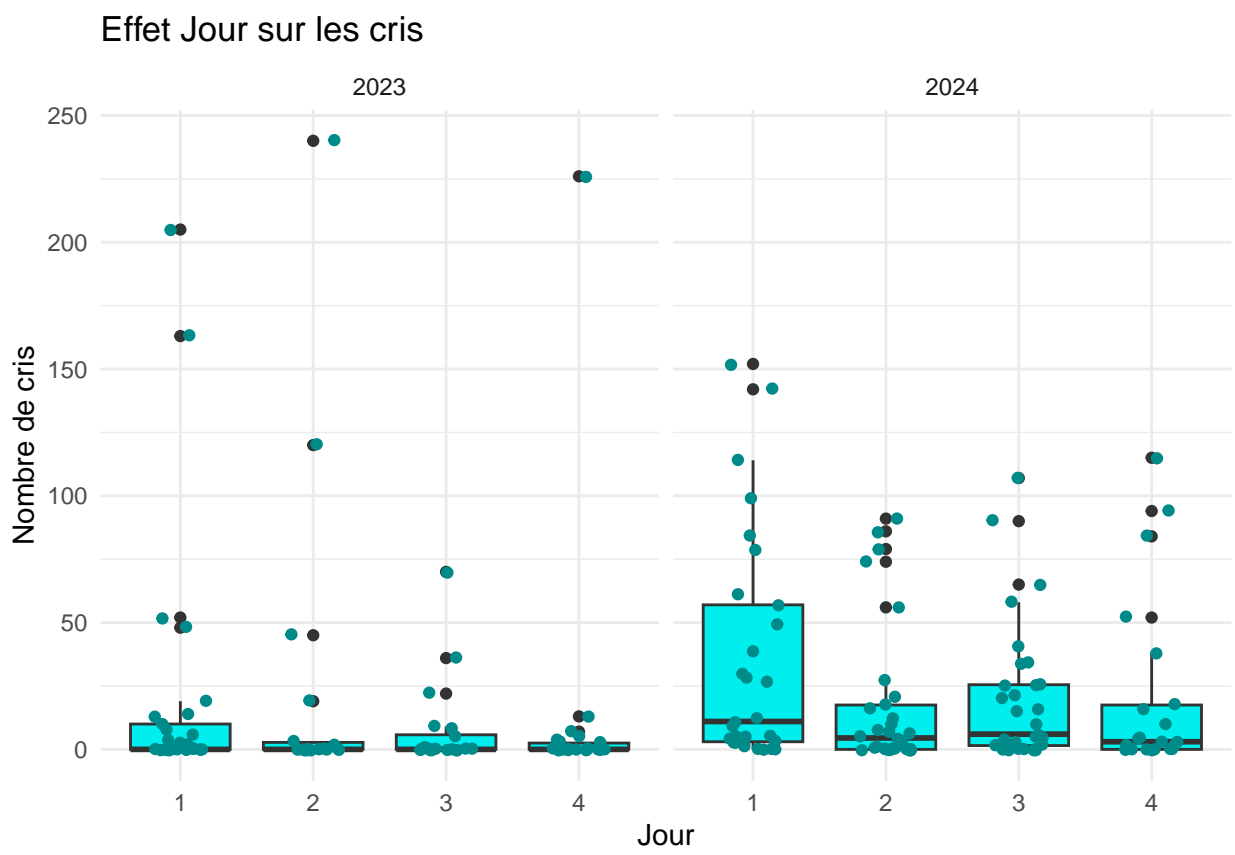


## Effet Jour sur la latence










## Effet Jour sur les survols



On ne semble pas observer de tendance d'atténuation de l'intensité de la réponse ni d'accoutumance des oiseaux avec le temps.

### C. Réponse de chacun des mâles

Nous regardons si certains mâles répondent plus que d'autres.

```
table_data_male <- data |> select(ID_MALE, LATENCE_BINAIRE) |> table()


table_data_count_n <- table_data_male |> data.frame() |>
  group_by(ID_MALE) |> mutate(N = sum(Freq)) |>
  filter(LATENCE_BINAIRE == 1) |> select(-LATENCE_BINAIRE) |>
  rename(REACTION=Freq)

table_data_ci <- table_data_count_n |>
  with(binom.confint(REACTION, N, methods="wilson")) |>
  select(x, mean, lower, upper) |>
  rename(REACTION=x, PROP=mean, LOWER=lower, UPPER=upper) |>
  mutate(ID_MALE=1:11)

table_final_male <- merge(
  table_data_count_n, table_data_ci, by=c("ID_MALE", "REACTION")
)

table_final_male$ID_MALE <- fct_reorder(
  table_final_male$ID_MALE, table_final_male$PROP, .desc = TRUE
)
```

```
ggplot(table_final_male, aes(x=ID_MALE, y=PROP)) +
  geom_col(fill = "#0073C2FF", width = 0.3) +
  geom_errorbar(aes(ymin = LOWER, ymax = UPPER), width=0.03) +
  theme_minimal() +
  labs(
    title="Pourcentage du temps où les individus réagissent",
    x="Mâles", y="Proportion de réaction"
  ) +
  geom_text(
    aes(label = round(PROP,2)), hjust=1.25,
    vjust = -1, color = "black"
  ) +
  ylim(0,1)
```




```
rm(table_data_count_n, table_data_ci)
```

Après avoir testé la réponse binaire des différents mâle, on cherche à tester l'intensité de leurs réponses. Pour cela, on utilise les données des oiseaux ayant répondu, donc le tableau `data_reponse`.


```
# Effet male sur la distance
ggplot(data_reponse) +
  geom_boxplot(aes(x=factor(ID_MALE,c(1:11)), y=DISTANCE_MIN)) +
  labs(x="Mâle", title = "Effet mâle sur la distance") +
  theme_minimal()
```

## Effet mâle sur la distance




```
ggplot(data_reponse, aes(x=DISTANCE_MIN_FACTOR, fill=ID_MALE)) +
  geom_bar() + facet_wrap(~ID_MALE, ncol=5) + theme_bw() +
  labs(
    title="Distances minimales d'approche selon la diffusion passée",
    x="Classe de distance minimale (m)",
    y="Compte"
  )
```

## Distances minimales d'approche selon la diffusion passée




```
# Effet male sur la latence
ggplot(data_reponse, aes(x=ID_MALE, y=LATENCE)) +
  geom_boxplot() + geom_jitter(width=0.2) +
  labs(x="Mâle", title = "Effet mâle sur la latence") +
  theme_minimal()
```


## Effet mâle sur la latence



```
# Effet male sur les chants
ggplot(data_reponse, aes(x=ID_MALE, y=STROPHES_APRES)) +
  geom_boxplot() + geom_jitter(width=0.2) +
  labs(x="Mâle", title = "Effet mâle sur les chants") +
  theme_minimal()
```




```
# Effet male sur les cris
ggplot(data_reponse, aes(x=ID_MALE, y=CRIS)) +
  geom_boxplot() + geom_jitter(width=0.2) +
  labs(x="Mâle", title = "Effet mâle sur les cris") +
  theme_minimal()
```



```
# Effet male sur les survols
ggplot(data_reponse, aes(x=ID_MALE, y=SURVOLS)) +
  geom_boxplot() + geom_jitter(width=0.2) +
  labs(x="Mâle", title = "Effet mâle sur les survols") +
  theme_minimal()
```



## Effet mâle sur les survols



On observe des disparités de réponse entre les mâles, mais on n'observe pas de mâle qui répondrait considérablement plus ou moins que les autres sur tous les critères d'activité. Les disparités semblent plutôt aléatoirement distribuées parmi les mâles et les critères d'activité. On cherche maintenant à tester statistiquement ces différences.

### 1. Test statistique de l'effet mâle sur les cris

```
##
## Call:
## MASS::glm.nb(formula = CRIS ~ ID_MALE, data = data_reponse, init.theta = 0.255563949,
##   link = log)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   2.3197      0.1511  15.351 < 2e-16 ***
## ID_MALE.L     -0.8310      0.5326  -1.560  0.118703
## ID_MALE.Q      1.4654      0.5308   2.761  0.005767 **
## ID_MALE.C      0.2048      0.5326   0.385  0.700595
## ID_MALE^4     -1.5099      0.5243  -2.880  0.003981 **
## ID_MALE^5     -2.3303      0.4623  -5.040  4.65e-07 ***
## ID_MALE^6     -0.5718      0.4804  -1.190  0.233978
## ID_MALE^7      0.5060      0.5037   1.004  0.315158
## ID_MALE^8     -1.6902      0.5064  -3.338  0.000844 ***
## ID_MALE^9      0.5708      0.4580   1.246  0.212701
## ID_MALE^10     0.8181      0.4724   1.732  0.083328 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```

##
## (Dispersion parameter for Negative Binomial(0.2556) family taken to be 1)
##
## Null deviance: 261.93 on 204 degrees of freedom
## Residual deviance: 204.52 on 194 degrees of freedom
## AIC: 1278.4
##
## Number of Fisher Scoring iterations: 1
##
## Theta: 0.2556
## Std. Err.: 0.0297
##
## 2 x log-likelihood: -1254.4440

## No variable was specified for contrast estimation. Selecting `contrast = "ID_MALE"`.

## Marginal Contrasts Analysis
##
## Level1 | Level2 | Difference | 95% CI | SE | df | z | p | p.signif
## -----|-----|-----|-----|----|----|---|---|-----
## ID_MALE1 | ID_MALE10 | -1.06 | [-3.24, 1.12] | 0.66 | Inf | -1.61 | 0.185 | ns
## ID_MALE1 | ID_MALE11 | 1.64 | [-1.11, 4.39] | 0.83 | Inf | 1.98 | 0.105 | ns
## ID_MALE1 | ID_MALE2 | 0.08 | [-1.76, 1.92] | 0.56 | Inf | 0.15 | 0.885 | ns
## ID_MALE1 | ID_MALE3 | 1.51 | [-0.62, 3.64] | 0.64 | Inf | 2.36 | 0.046 | *
## ID_MALE1 | ID_MALE4 | -0.43 | [-2.37, 1.51] | 0.59 | Inf | -0.73 | 0.568 | ns
## ID_MALE1 | ID_MALE5 | 0.27 | [-1.74, 2.29] | 0.61 | Inf | 0.45 | 0.717 | ns
## ID_MALE1 | ID_MALE6 | 2.92 | [ 0.71, 5.14] | 0.67 | Inf | 4.38 | < .001 | ***
## ID_MALE1 | ID_MALE7 | 1.93 | [-0.06, 3.93] | 0.60 | Inf | 3.21 | 0.005 | **
## ID_MALE1 | ID_MALE8 | 2.11 | [ 0.08, 4.14] | 0.61 | Inf | 3.45 | 0.003 | **
## ID_MALE1 | ID_MALE9 | 0.96 | [-1.55, 3.47] | 0.76 | Inf | 1.27 | 0.308 | ns
## ID_MALE10 | ID_MALE11 | 2.70 | [-0.22, 5.62] | 0.88 | Inf | 3.06 | 0.008 | **
## ID_MALE2 | ID_MALE10 | -1.14 | [-3.23, 0.95] | 0.63 | Inf | -1.81 | 0.129 | ns
## ID_MALE2 | ID_MALE11 | 1.56 | [-1.12, 4.24] | 0.81 | Inf | 1.93 | 0.109 | ns
## ID_MALE2 | ID_MALE3 | 1.43 | [-0.60, 3.47] | 0.61 | Inf | 2.33 | 0.047 | *
## ID_MALE2 | ID_MALE4 | -0.51 | [-2.35, 1.33] | 0.55 | Inf | -0.92 | 0.468 | ns
## ID_MALE2 | ID_MALE5 | 0.19 | [-1.73, 2.11] | 0.58 | Inf | 0.33 | 0.781 | ns
## ID_MALE2 | ID_MALE6 | 2.84 | [ 0.72, 4.96] | 0.64 | Inf | 4.44 | < .001 | ***
## ID_MALE2 | ID_MALE7 | 1.85 | [-0.04, 3.75] | 0.57 | Inf | 3.24 | 0.005 | **
## ID_MALE2 | ID_MALE8 | 2.03 | [ 0.10, 3.96] | 0.58 | Inf | 3.49 | 0.002 | **
## ID_MALE2 | ID_MALE9 | 0.88 | [-1.55, 3.31] | 0.73 | Inf | 1.20 | 0.332 | ns
## ID_MALE3 | ID_MALE10 | -2.57 | [-4.93, -0.22] | 0.71 | Inf | -3.63 | 0.002 | **
## ID_MALE3 | ID_MALE11 | 0.13 | [-2.76, 3.01] | 0.87 | Inf | 0.14 | 0.885 | ns
## ID_MALE3 | ID_MALE4 | -1.94 | [-4.07, 0.19] | 0.64 | Inf | -3.03 | 0.009 | **
## ID_MALE3 | ID_MALE5 | -1.24 | [-3.44, 0.96] | 0.66 | Inf | -1.87 | 0.121 | ns
## ID_MALE3 | ID_MALE6 | 1.41 | [-0.97, 3.79] | 0.72 | Inf | 1.96 | 0.105 | ns
## ID_MALE3 | ID_MALE7 | 0.42 | [-1.76, 2.60] | 0.66 | Inf | 0.64 | 0.600 | ns
## ID_MALE3 | ID_MALE8 | 0.60 | [-1.61, 2.80] | 0.67 | Inf | 0.90 | 0.468 | ns
## ID_MALE3 | ID_MALE9 | -0.55 | [-3.21, 2.11] | 0.80 | Inf | -0.69 | 0.575 | ns
## ID_MALE4 | ID_MALE10 | -0.63 | [-2.81, 1.55] | 0.66 | Inf | -0.96 | 0.452 | ns
## ID_MALE4 | ID_MALE11 | 2.07 | [-0.68, 4.82] | 0.83 | Inf | 2.50 | 0.036 | *
## ID_MALE4 | ID_MALE5 | 0.70 | [-1.31, 2.72] | 0.61 | Inf | 1.16 | 0.341 | ns
## ID_MALE4 | ID_MALE6 | 3.35 | [ 1.14, 5.56] | 0.67 | Inf | 5.02 | < .001 | ****
## ID_MALE4 | ID_MALE7 | 2.36 | [ 0.37, 4.36] | 0.60 | Inf | 3.93 | < .001 | ***
## ID_MALE4 | ID_MALE8 | 2.54 | [ 0.51, 4.56] | 0.61 | Inf | 4.15 | < .001 | ***

```

```
## ID_MALE4 | ID_MALE9 | 1.39 | [-1.12, 3.90] | 0.76 | Inf | 1.84 | 0.126 | ns
## ID_MALE5 | ID_MALE10 | -1.33 | [-3.58, 0.92] | 0.68 | Inf | -1.97 | 0.105 | ns
## ID_MALE5 | ID_MALE11 | 1.37 | [-1.44, 4.17] | 0.84 | Inf | 1.62 | 0.185 | ns
## ID_MALE5 | ID_MALE6 | 2.65 | [ 0.37, 4.93] | 0.69 | Inf | 3.85 | < .001 | ***
## ID_MALE5 | ID_MALE7 | 1.66 | [-0.41, 3.73] | 0.62 | Inf | 2.66 | 0.024 | *
## ID_MALE5 | ID_MALE8 | 1.84 | [-0.26, 3.93] | 0.63 | Inf | 2.90 | 0.012 | *
## ID_MALE5 | ID_MALE9 | 0.69 | [-1.88, 3.26] | 0.77 | Inf | 0.89 | 0.468 | ns
## ID_MALE6 | ID_MALE10 | -3.98 | [-6.41, -1.55] | 0.73 | Inf | -5.44 | < .001 | ****
## ID_MALE6 | ID_MALE11 | -1.28 | [-4.23, 1.66] | 0.89 | Inf | -1.44 | 0.234 | ns
## ID_MALE6 | ID_MALE7 | -0.99 | [-3.25, 1.27] | 0.68 | Inf | -1.45 | 0.234 | ns
## ID_MALE6 | ID_MALE8 | -0.81 | [-3.10, 1.48] | 0.69 | Inf | -1.18 | 0.337 | ns
## ID_MALE6 | ID_MALE9 | -1.96 | [-4.69, 0.77] | 0.82 | Inf | -2.38 | 0.045 | *
## ID_MALE7 | ID_MALE10 | -2.99 | [-5.22, -0.76] | 0.67 | Inf | -4.45 | < .001 | ***
## ID_MALE7 | ID_MALE11 | -0.29 | [-3.08, 2.49] | 0.84 | Inf | -0.35 | 0.781 | ns
## ID_MALE7 | ID_MALE8 | 0.18 | [-1.90, 2.25] | 0.63 | Inf | 0.28 | 0.807 | ns
## ID_MALE7 | ID_MALE9 | -0.97 | [-3.52, 1.58] | 0.77 | Inf | -1.26 | 0.308 | ns
## ID_MALE8 | ID_MALE10 | -3.17 | [-5.43, -0.91] | 0.68 | Inf | -4.65 | < .001 | ****
## ID_MALE8 | ID_MALE11 | -0.47 | [-3.28, 2.34] | 0.85 | Inf | -0.55 | 0.650 | ns
## ID_MALE8 | ID_MALE9 | -1.15 | [-3.72, 1.43] | 0.78 | Inf | -1.48 | 0.233 | ns
## ID_MALE9 | ID_MALE10 | -2.02 | [-4.72, 0.68] | 0.81 | Inf | -2.48 | 0.036 | *
## ID_MALE9 | ID_MALE11 | 0.68 | [-2.50, 3.85] | 0.96 | Inf | 0.71 | 0.573 | ns
##
## Marginal contrasts estimated at ID_MALE
## p-value adjustment method: Benjamini & Hochberg (1995)
```

On observe que quasiment tous les mâles sont statistiquement différents les uns des autres en ce qui concerne le nombre de cris.

```
test_male_chant <- MASS::glm.nb(
  STROPHES_APRES~ID_MALE, data=data_reponse
)
test_male_chant |> summary()
```

## 2. Test statistique de l'effet mâle sur les chants

```
##
## Call:
## MASS::glm.nb(formula = STROPHES_APRES ~ ID_MALE, data = data_reponse,
##   init.theta = 1.016670305, link = log)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  1.45317    0.08468  17.160 < 2e-16 ***
## ID_MALE.L    -0.58136    0.30111  -1.931  0.05352 .
## ID_MALE.Q    -0.32724    0.28761  -1.138  0.25520
## ID_MALE.C    -0.01648    0.29863  -0.055  0.95598
## ID_MALE^4     0.87992    0.29794   2.953  0.00314 **
## ID_MALE^5     0.40129    0.25768   1.557  0.11939
## ID_MALE^6     0.05563    0.27200   0.205  0.83796
## ID_MALE^7     0.06137    0.29546   0.208  0.83546
## ID_MALE^8    -0.92824    0.29035  -3.197  0.00139 **
## ID_MALE^9    -0.77177    0.25213  -3.061  0.00221 **
## ID_MALE^10    0.23232    0.24888   0.933  0.35059
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(1.0167) family taken to be 1)
##
##      Null deviance: 270.30  on 204  degrees of freedom
## Residual deviance: 236.03  on 194  degrees of freedom
## AIC: 1112.2
##
## Number of Fisher Scoring iterations: 1
##
##              Theta:  1.017
##             Std. Err.:  0.135
##
## 2 x log-likelihood: -1088.187
```

```
test_male_chant |> estimate_contrasts(p_adjust="fdr") |>
  add_significance()
```

```
## No variable was specified for contrast estimation. Selecting `contrast = "ID_MALE"`.
## Marginal Contrasts Analysis
##
```

## Level1	Level2	Difference	95% CI	SE	df	z	p	p.signif
## ID_MALE1	ID_MALE10	0.92	[-0.34, 2.18]	0.38	Inf	2.43	0.060	ns
## ID_MALE1	ID_MALE11	0.38	[-1.12, 1.88]	0.45	Inf	0.85	0.559	ns
## ID_MALE1	ID_MALE2	0.18	[-0.82, 1.18]	0.30	Inf	0.60	0.665	ns
## ID_MALE1	ID_MALE3	0.61	[-0.57, 1.79]	0.36	Inf	1.73	0.193	ns
## ID_MALE1	ID_MALE4	0.36	[-0.71, 1.43]	0.32	Inf	1.12	0.410	ns
## ID_MALE1	ID_MALE5	-0.45	[-1.53, 0.62]	0.32	Inf	-1.41	0.293	ns
## ID_MALE1	ID_MALE6	0.44	[-0.72, 1.61]	0.35	Inf	1.26	0.344	ns
## ID_MALE1	ID_MALE7	0.10	[-0.97, 1.17]	0.32	Inf	0.31	0.835	ns
## ID_MALE1	ID_MALE8	-0.43	[-1.49, 0.63]	0.32	Inf	-1.35	0.312	ns
## ID_MALE1	ID_MALE9	1.36	[-0.17, 2.90]	0.46	Inf	2.94	0.027	*
## ID_MALE10	ID_MALE11	-0.54	[-2.19, 1.11]	0.50	Inf	-1.08	0.427	ns
## ID_MALE2	ID_MALE10	0.74	[-0.48, 1.96]	0.37	Inf	2.02	0.128	ns
## ID_MALE2	ID_MALE11	0.20	[-1.26, 1.67]	0.44	Inf	0.46	0.741	ns
## ID_MALE2	ID_MALE3	0.43	[-0.70, 1.57]	0.34	Inf	1.26	0.344	ns
## ID_MALE2	ID_MALE4	0.18	[-0.84, 1.20]	0.31	Inf	0.59	0.665	ns
## ID_MALE2	ID_MALE5	-0.64	[-1.66, 0.39]	0.31	Inf	-2.06	0.128	ns
## ID_MALE2	ID_MALE6	0.26	[-0.86, 1.39]	0.34	Inf	0.78	0.586	ns
## ID_MALE2	ID_MALE7	-0.08	[-1.10, 0.94]	0.31	Inf	-0.27	0.850	ns
## ID_MALE2	ID_MALE8	-0.61	[-1.63, 0.40]	0.31	Inf	-2.01	0.128	ns
## ID_MALE2	ID_MALE9	1.18	[-0.32, 2.69]	0.45	Inf	2.61	0.056	ns
## ID_MALE3	ID_MALE10	0.31	[-1.06, 1.68]	0.41	Inf	0.75	0.596	ns
## ID_MALE3	ID_MALE11	-0.23	[-1.82, 1.36]	0.48	Inf	-0.48	0.739	ns
## ID_MALE3	ID_MALE4	-0.25	[-1.45, 0.94]	0.36	Inf	-0.70	0.619	ns
## ID_MALE3	ID_MALE5	-1.07	[-2.27, 0.13]	0.36	Inf	-2.95	0.027	*
## ID_MALE3	ID_MALE6	-0.17	[-1.45, 1.11]	0.39	Inf	-0.44	0.742	ns
## ID_MALE3	ID_MALE7	-0.52	[-1.71, 0.68]	0.36	Inf	-1.43	0.289	ns
## ID_MALE3	ID_MALE8	-1.05	[-2.24, 0.14]	0.36	Inf	-2.92	0.027	*
## ID_MALE3	ID_MALE9	0.75	[-0.88, 2.38]	0.49	Inf	1.53	0.258	ns
## ID_MALE4	ID_MALE10	0.56	[-0.71, 1.83]	0.38	Inf	1.46	0.284	ns
## ID_MALE4	ID_MALE11	0.02	[-1.49, 1.53]	0.46	Inf	0.05	0.962	ns

## ID_MALE4	ID_MALE5		-0.82	[-1.91, 0.27]		0.33	Inf		-2.49		0.060		ns
## ID_MALE4	ID_MALE6		0.08	[-1.10, 1.26]		0.36	Inf		0.23		0.865		ns
## ID_MALE4	ID_MALE7		-0.26	[-1.35, 0.82]		0.33	Inf		-0.81		0.578		ns
## ID_MALE4	ID_MALE8		-0.79	[-1.87, 0.28]		0.32	Inf		-2.45		0.060		ns
## ID_MALE4	ID_MALE9		1.00	[-0.55, 2.55]		0.47	Inf		2.14		0.110		ns
## ID_MALE5	ID_MALE10		1.38	[ 0.10, 2.66]		0.39	Inf		3.57		0.005		**
## ID_MALE5	ID_MALE11		0.84	[-0.68, 2.35]		0.46	Inf		1.83		0.174		ns
## ID_MALE5	ID_MALE6		0.90	[-0.29, 2.09]		0.36	Inf		2.51		0.060		ns
## ID_MALE5	ID_MALE7		0.55	[-0.54, 1.64]		0.33	Inf		1.69		0.202		ns
## ID_MALE5	ID_MALE8		0.02	[-1.06, 1.11]		0.33	Inf		0.07		0.962		ns
## ID_MALE5	ID_MALE9		1.82	[ 0.26, 3.37]		0.47	Inf		3.88		0.003		**
## ID_MALE6	ID_MALE10		0.48	[-0.88, 1.84]		0.41	Inf		1.17		0.393		ns
## ID_MALE6	ID_MALE11		-0.06	[-1.64, 1.52]		0.48	Inf		-0.13		0.933		ns
## ID_MALE6	ID_MALE7		-0.35	[-1.53, 0.84]		0.36	Inf		-0.97		0.493		ns
## ID_MALE6	ID_MALE8		-0.88	[-2.05, 0.30]		0.35	Inf		-2.47		0.060		ns
## ID_MALE6	ID_MALE9		0.92	[-0.70, 2.54]		0.49	Inf		1.88		0.164		ns
## ID_MALE7	ID_MALE10		0.82	[-0.45, 2.10]		0.38	Inf		2.15		0.110		ns
## ID_MALE7	ID_MALE11		0.28	[-1.23, 1.80]		0.46	Inf		0.63		0.665		ns
## ID_MALE7	ID_MALE8		-0.53	[-1.61, 0.55]		0.32	Inf		-1.64		0.215		ns
## ID_MALE7	ID_MALE9		1.27	[-0.28, 2.82]		0.47	Inf		2.71		0.046		*
## ID_MALE8	ID_MALE10		1.36	[ 0.09, 2.62]		0.38	Inf		3.54		0.005		**
## ID_MALE8	ID_MALE11		0.82	[-0.69, 2.32]		0.45	Inf		1.80		0.181		ns
## ID_MALE8	ID_MALE9		1.80	[ 0.25, 3.34]		0.47	Inf		3.86		0.003		**
## ID_MALE9	ID_MALE10		-0.44	[-2.13, 1.25]		0.51	Inf		-0.87		0.558		ns
## ID_MALE9	ID_MALE11		-0.98	[-2.86, 0.89]		0.57	Inf		-1.74		0.193		ns

##

## Marginal contrasts estimated at ID\_MALE

## p-value adjustment method: Benjamini & Hochberg (1995)

On observe que la plupart des mâles sont statistiquement différents les uns des autres en ce qui concerne le nombre de chants également. De plus, le calcul du pseudo- $R^2$  nous permet d'observer que l'effet mâle explique  $\sim 70\%$  de la variance des chants, ce qui est non négligeable.

```
test_male_survols <- MASS::glm.nb(
  SURVOLS~ID_MALE, data=data_reponse
)
test_male_survols |> summary()
```

### 3. Test statistique de l'effet mâle sur les survols

##

## Call:

## MASS::glm.nb(formula = SURVOLS ~ ID\_MALE, data = data\_reponse,

## init.theta = 2.139168892, link = log)

##

## Coefficients:

	Estimate	Std. Error	z value	Pr(> z )
## (Intercept)	-0.26630	0.10833	-2.458	0.01397 *
## ID_MALE.L	-0.69238	0.38619	-1.793	0.07299 .
## ID_MALE.Q	0.16335	0.37108	0.440	0.65979
## ID_MALE.C	-0.05793	0.39766	-0.146	0.88418
## ID_MALE^4	0.09527	0.38037	0.250	0.80223
## ID_MALE^5	-0.25711	0.31070	-0.828	0.40794
## ID_MALE^6	-0.41231	0.32012	-1.288	0.19775

```

## ID_MALE^7    -0.80384    0.39819   -2.019   0.04351 *
## ID_MALE^8    -0.14883    0.36885   -0.403   0.68658
## ID_MALE^9    -0.33647    0.33494   -1.005   0.31510
## ID_MALE^10   -0.84951    0.30905   -2.749   0.00598 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(2.1392) family taken to be 1)
##
##      Null deviance: 225.80  on 204  degrees of freedom
## Residual deviance: 208.96  on 194  degrees of freedom
## AIC: 536.41
##
## Number of Fisher Scoring iterations: 1
##
##              Theta:  2.139
##             Std. Err.: 0.851
##
## 2 x log-likelihood: -512.406

```

```

test_male_survols |> estimate_contrasts(p_adjust="fdr") |>
  add_significance()

```

```

## No variable was specified for contrast estimation. Selecting `contrast = "ID_MALE"`.
## Marginal Contrasts Analysis
##
## Level1 | Level2 | Difference | 95% CI | SE | df | z | p | p.signif
## -----|-----|-----|-----|---|---|---|---|---|
## ID_MALE1 | ID_MALE10 | 0.14 | [-1.12, 1.40] | 0.38 | Inf | 0.37 | 0.832 | ns
## ID_MALE1 | ID_MALE11 | 0.96 | [-1.04, 2.95] | 0.60 | Inf | 1.59 | 0.407 | ns
## ID_MALE1 | ID_MALE2 | 0.45 | [-0.65, 1.56] | 0.33 | Inf | 1.36 | 0.490 | ns
## ID_MALE1 | ID_MALE3 | 0.21 | [-1.02, 1.44] | 0.37 | Inf | 0.56 | 0.733 | ns
## ID_MALE1 | ID_MALE4 | 0.41 | [-0.76, 1.57] | 0.35 | Inf | 1.15 | 0.490 | ns
## ID_MALE1 | ID_MALE5 | 0.96 | [-0.44, 2.35] | 0.42 | Inf | 2.28 | 0.276 | ns
## ID_MALE1 | ID_MALE6 | -0.04 | [-1.21, 1.13] | 0.35 | Inf | -0.10 | 0.959 | ns
## ID_MALE1 | ID_MALE7 | 0.87 | [-0.45, 2.19] | 0.40 | Inf | 2.19 | 0.276 | ns
## ID_MALE1 | ID_MALE8 | 0.42 | [-0.78, 1.62] | 0.36 | Inf | 1.16 | 0.490 | ns
## ID_MALE1 | ID_MALE9 | 1.47 | [-0.72, 3.65] | 0.66 | Inf | 2.23 | 0.276 | ns
## ID_MALE10 | ID_MALE11 | 0.82 | [-1.28, 2.91] | 0.63 | Inf | 1.30 | 0.490 | ns
## ID_MALE2 | ID_MALE10 | -0.31 | [-1.59, 0.96] | 0.38 | Inf | -0.82 | 0.632 | ns
## ID_MALE2 | ID_MALE11 | 0.50 | [-1.50, 2.51] | 0.61 | Inf | 0.83 | 0.632 | ns
## ID_MALE2 | ID_MALE3 | -0.25 | [-1.49, 1.00] | 0.38 | Inf | -0.66 | 0.703 | ns
## ID_MALE2 | ID_MALE4 | -0.05 | [-1.24, 1.14] | 0.36 | Inf | -0.14 | 0.959 | ns
## ID_MALE2 | ID_MALE5 | 0.50 | [-0.91, 1.92] | 0.43 | Inf | 1.18 | 0.490 | ns
## ID_MALE2 | ID_MALE6 | -0.49 | [-1.68, 0.70] | 0.36 | Inf | -1.37 | 0.490 | ns
## ID_MALE2 | ID_MALE7 | 0.42 | [-0.92, 1.75] | 0.40 | Inf | 1.03 | 0.534 | ns
## ID_MALE2 | ID_MALE8 | -0.04 | [-1.26, 1.19] | 0.37 | Inf | -0.10 | 0.959 | ns
## ID_MALE2 | ID_MALE9 | 1.01 | [-1.18, 3.21] | 0.66 | Inf | 1.53 | 0.407 | ns
## ID_MALE3 | ID_MALE10 | -0.07 | [-1.45, 1.31] | 0.42 | Inf | -0.16 | 0.959 | ns
## ID_MALE3 | ID_MALE11 | 0.75 | [-1.33, 2.83] | 0.63 | Inf | 1.20 | 0.490 | ns
## ID_MALE3 | ID_MALE4 | 0.20 | [-1.10, 1.50] | 0.39 | Inf | 0.50 | 0.752 | ns
## ID_MALE3 | ID_MALE5 | 0.75 | [-0.76, 2.26] | 0.45 | Inf | 1.65 | 0.407 | ns
## ID_MALE3 | ID_MALE6 | -0.25 | [-1.55, 1.06] | 0.39 | Inf | -0.62 | 0.705 | ns

```

```
## ID_MALE3 | ID_MALE7 | 0.66 | [-0.77, 2.10] | 0.43 | Inf | 1.53 | 0.407 | ns
## ID_MALE3 | ID_MALE8 | 0.21 | [-1.12, 1.54] | 0.40 | Inf | 0.53 | 0.748 | ns
## ID_MALE3 | ID_MALE9 | 1.26 | [-1.00, 3.52] | 0.68 | Inf | 1.85 | 0.407 | ns
## ID_MALE4 | ID_MALE10 | -0.26 | [-1.59, 1.06] | 0.40 | Inf | -0.66 | 0.703 | ns
## ID_MALE4 | ID_MALE11 | 0.55 | [-1.49, 2.59] | 0.62 | Inf | 0.90 | 0.632 | ns
## ID_MALE4 | ID_MALE5 | 0.55 | [-0.91, 2.01] | 0.44 | Inf | 1.26 | 0.490 | ns
## ID_MALE4 | ID_MALE6 | -0.44 | [-1.69, 0.80] | 0.38 | Inf | -1.18 | 0.490 | ns
## ID_MALE4 | ID_MALE7 | 0.47 | [-0.92, 1.85] | 0.42 | Inf | 1.12 | 0.502 | ns
## ID_MALE4 | ID_MALE8 | 0.01 | [-1.26, 1.29] | 0.38 | Inf | 0.04 | 0.988 | ns
## ID_MALE4 | ID_MALE9 | 1.06 | [-1.16, 3.29] | 0.67 | Inf | 1.59 | 0.407 | ns
## ID_MALE5 | ID_MALE10 | -0.82 | [-2.35, 0.71] | 0.46 | Inf | -1.77 | 0.407 | ns
## ID_MALE5 | ID_MALE11 | -2.84e-15 | [-2.18, 2.18] | 0.66 | Inf | -4.33e-15 | > .999 | ns
## ID_MALE5 | ID_MALE6 | -1.00 | [-2.46, 0.47] | 0.44 | Inf | -2.26 | 0.276 | ns
## ID_MALE5 | ID_MALE7 | -0.09 | [-1.67, 1.50] | 0.48 | Inf | -0.18 | 0.959 | ns
## ID_MALE5 | ID_MALE8 | -0.54 | [-2.03, 0.95] | 0.45 | Inf | -1.20 | 0.490 | ns
## ID_MALE5 | ID_MALE9 | 0.51 | [-1.84, 2.86] | 0.71 | Inf | 0.72 | 0.701 | ns
## ID_MALE6 | ID_MALE10 | 0.18 | [-1.15, 1.51] | 0.40 | Inf | 0.44 | 0.788 | ns
## ID_MALE6 | ID_MALE11 | 1.00 | [-1.05, 3.04] | 0.62 | Inf | 1.62 | 0.407 | ns
## ID_MALE6 | ID_MALE7 | 0.91 | [-0.48, 2.30] | 0.42 | Inf | 2.17 | 0.276 | ns
## ID_MALE6 | ID_MALE8 | 0.46 | [-0.82, 1.74] | 0.39 | Inf | 1.18 | 0.490 | ns
## ID_MALE6 | ID_MALE9 | 1.51 | [-0.72, 3.73] | 0.67 | Inf | 2.24 | 0.276 | ns
## ID_MALE7 | ID_MALE10 | -0.73 | [-2.19, 0.73] | 0.44 | Inf | -1.66 | 0.407 | ns
## ID_MALE7 | ID_MALE11 | 0.09 | [-2.04, 2.22] | 0.64 | Inf | 0.14 | 0.959 | ns
## ID_MALE7 | ID_MALE8 | -0.45 | [-1.87, 0.96] | 0.43 | Inf | -1.06 | 0.532 | ns
## ID_MALE7 | ID_MALE9 | 0.60 | [-1.71, 2.91] | 0.70 | Inf | 0.86 | 0.632 | ns
## ID_MALE8 | ID_MALE10 | -0.28 | [-1.64, 1.08] | 0.41 | Inf | -0.68 | 0.703 | ns
## ID_MALE8 | ID_MALE11 | 0.54 | [-1.52, 2.60] | 0.62 | Inf | 0.87 | 0.632 | ns
## ID_MALE8 | ID_MALE9 | 1.05 | [-1.19, 3.29] | 0.68 | Inf | 1.55 | 0.407 | ns
## ID_MALE9 | ID_MALE10 | -1.33 | [-3.60, 0.95] | 0.69 | Inf | -1.94 | 0.407 | ns
## ID_MALE9 | ID_MALE11 | -0.51 | [-3.26, 2.24] | 0.83 | Inf | -0.62 | 0.705 | ns
##
```

## Marginal contrasts estimated at ID\_MALE

## p-value adjustment method: Benjamini & Hochberg (1995)

On observe que aucun mâle n'est différent des autres en ce qui concerne le nombre de survols.

#### 4. Test statistique de l'effet mâle sur la latence

```
##
## Kruskal-Wallis rank sum test
##
## data: LATENCE by ID_MALE
## Kruskal-Wallis chi-squared = 22.22, df = 10, p-value = 0.01402
## # A tibble: 55 x 7
##   group1 group2  n1  n2 statistic p.adj p.adj.signif
##   <chr> <chr> <int> <int> <dbl> <dbl> <chr>
## 1 1 2 23 29 -0.0605 0.952 ns
## 2 1 3 23 17 1.90 0.245 ns
## 3 1 4 23 23 1.59 0.294 ns
## 4 1 5 23 20 2.43 0.117 ns
## 5 1 6 23 17 1.55 0.303 ns
## 6 1 7 23 22 0.490 0.780 ns
## 7 1 8 23 21 1.08 0.481 ns
## 8 1 9 23 10 0.251 0.848 ns
```

```
## 9 1      10      23  15 -0.342 0.821 ns
## 10 1     11      23   8  2.99  0.0510 ns
## # i 45 more rows
```

Il n'y a pas de mâle différent d'un autre en terme de latence non plus.

## 5. Test statistique de l'effet mâle sur la distance à l'enceinte

```
##
## Kruskal-Wallis rank sum test
##
## data:  DISTANCE_MIN_FACTOR by ID_MALE
## Kruskal-Wallis chi-squared = 35.098, df = 10, p-value = 0.0001201

## # A tibble: 55 x 7
##   group1 group2  n1  n2 statistic  p.adj p.adj.signif
##   <chr>  <chr> <int> <int>    <dbl>  <dbl> <chr>
## 1 1      2      23  29     2.06  0.124 ns
## 2 1      3      23  17     2.65  0.0495 *
## 3 1      4      23  23     2.02  0.124 ns
## 4 1      5      23  20     3.48  0.00916 **
## 5 1      6      23  17    -0.867 0.590 ns
## 6 1      7      23  22     1.40  0.308 ns
## 7 1      8      23  21    -0.365 0.800 ns
## 8 1      9      23  10     1.87  0.154 ns
## 9 1     10      23  15    -0.206 0.885 ns
## 10 1     11      23   8     0.846 0.591 ns
## # i 45 more rows
```

On observe que quelques mâles sont statistiquement différents les uns des autres en ce qui concerne la distance d'approche.

On peut conclure de ces tests statistiques que l'effet mâle est un facteur important de la variance de l'intensité de la réponse des oiseaux. Certains mâles poussent plus de cris, d'autres chantent plus et ont plus ou moins tendance à se rapprocher et à survoler l'enceinte.

Cela explique pourquoi le BIC a peu pénalisé les modèles mixtes ci-dessus, ces derniers prenant en compte un facteur entrant en jeu dans la variance de nos résultats.


## D. Etude des effets de l'environnement sur la réponse des mâles FTN

Nous allons tout d'abord nous intéresser à l'évolution des paramètres environnementaux en fonction du temps pour chaque jour de terrain.

NB : toutes les données météo ont été récoltées sur le site : [infoclimat.fr](http://infoclimat.fr)

**1. Température** Nous représentons d'abord l'évolution de la température en fonction du temps.






Nous voyons bien que la température augmente au cours de la journée. En revanche, il est compliqué de conclure quant à la proportion de réponses par rapport au nombre d'observations avec ce graphique...

**2. Ensoleillement** On s'intéresse maintenant à l'ensoleillement.

```
## `geom_smooth()` using method = 'loess' and formula = 'y ~ x'
```


## Réponse – Ensoleillement




**3. Vent** Nous avons deux variables, mais étant donné que `VENT_MAX` est parfaitement corrélée à `VENT_MOY` mais plus bruitées, nous garderons seulement la seconde.

```
## `geom_smooth()` using method = 'loess' and formula = 'y ~ x'
```

## Réponse – Vents moy

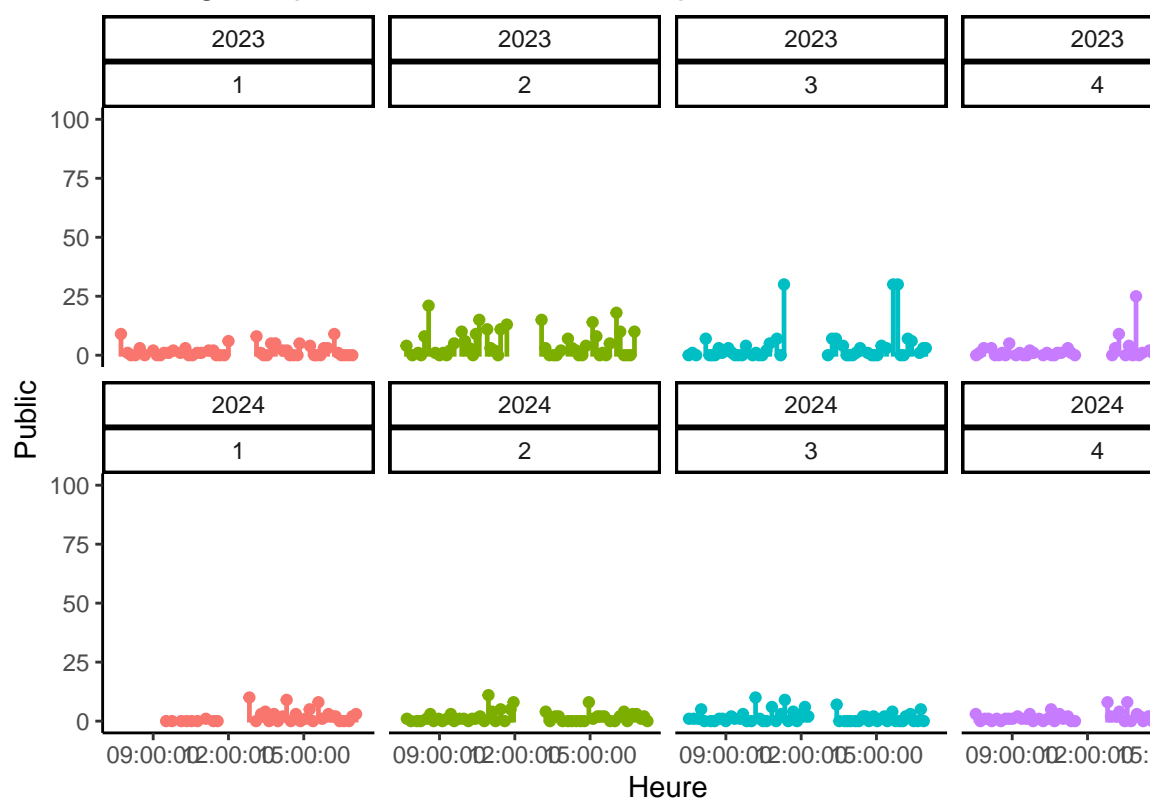


**4. Pluie** Il n'a plu que mardi 9 avril 2024 matin et le premier jour d'observation de 2023, donc on trace l'évolution des précipitations uniquement pour ces jours là. Etant donné que nous n'avons qu'un seul jour de précipitations par année dans nos données, nous avons décidé de négliger cette variable dans nos analyses.



En plus des données météo, d'autres facteurs environnementaux peuvent être étudiés comme le passage du public pendant nos observations sur les différents territoires, mais aussi l'effet de l'heure de la journée.

Passage du public en fonction du temps




## 5. Passage du public

2024 : Un résultat plutôt logique et cohérent avec ce que l'on a observé sur le terrain : il y a plus de passages sur l'intervalle [10h;16h] dans le parc, que tôt le matin et en fin de journée. 2023 : une valeur aberrante à 100 pour le dénombrement du public, mais même tendance qu'en 2024.

C'est la seule conclusion que l'on peut tirer de ce graphique. Il peut aussi être intéressant de regarder pour quels territoires il y avait le plus de passages, pour déceler un éventuel biais d'analyse :

## Passage du public en fonction des territoires



2024 : les territoires où il y avait le plus de passage étaient les territoires 1 et 3. On s'attend à voir un effet plus important pour ces mâles (s'il y en a un). 2023 : on décèle un peu plus de passage pour les territoires 6, 10 et 11. On s'attend à voir un effet plus important pour ces mâles (s'il y en a un).

**6. Analyse statistique de l'effet de l'environnement sur différentes variables** On commence par tester la variable LATENCE\_BINAIRE.

```
##
## Call:
## glm(formula = LATENCE_BINAIRE ~ TEMPERATURE * ENSOLEILLEMENT *
##       HEURE * PUBLIC * VENT_MOY, family = "binomial", data = data)
##
## Coefficients:
##                                     Estimate Std. Error z value
## (Intercept)                    -8.313e+00  7.621e+00  -1.091
## TEMPERATURE                     6.241e-01  6.092e-01   1.025
## ENSOLEILLEMENT                  -2.004e-02  2.086e-02  -0.961
## HEURE                          2.678e-04  2.251e-04   1.190
## PUBLIC                         -2.044e+00  3.018e+00  -0.677
## VENT_MOY                       2.731e+00  1.327e+00   2.058
## TEMPERATURE:ENSOLEILLEMENT      7.888e-04  1.413e-03   0.558
## TEMPERATURE:HEURE               -1.665e-05  1.559e-05  -1.067
## ENSOLEILLEMENT:HEURE            3.914e-07  4.971e-07   0.787
## TEMPERATURE:PUBLIC              2.192e-01  2.459e-01   0.892
## ENSOLEILLEMENT:PUBLIC           4.057e-03  5.491e-03   0.739
## HEURE:PUBLIC                    4.964e-05  7.946e-05   0.625
## TEMPERATURE:VENT_MOY           -1.868e-01  9.743e-02  -1.917
```

## ENSOLEILLEMENT:VENT_MOY	-3.266e-04	2.967e-03	-0.110
## HEURE:VENT_MOY	-7.065e-05	3.563e-05	-1.983
## PUBLIC:VENT_MOY	-1.138e-01	5.708e-01	-0.199
## TEMPERATURE:ENSOLEILLEMENT:HEURE	-1.728e-08	3.230e-08	-0.535
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC	-4.372e-04	4.070e-04	-1.074
## TEMPERATURE:HEURE:PUBLIC	-4.990e-06	5.363e-06	-0.930
## ENSOLEILLEMENT:HEURE:PUBLIC	-9.931e-08	1.377e-07	-0.721
## TEMPERATURE:ENSOLEILLEMENT:VENT_MOY	7.316e-05	2.061e-04	0.355
## TEMPERATURE:HEURE:VENT_MOY	4.541e-06	2.437e-06	1.863
## ENSOLEILLEMENT:HEURE:VENT_MOY	2.194e-08	6.815e-08	0.322
## TEMPERATURE:PUBLIC:VENT_MOY	1.339e-03	4.042e-02	0.033
## ENSOLEILLEMENT:PUBLIC:VENT_MOY	-1.459e-04	9.256e-04	-0.158
## HEURE:PUBLIC:VENT_MOY	2.563e-06	1.345e-05	0.191
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC	9.843e-09	8.857e-09	1.111
## TEMPERATURE:ENSOLEILLEMENT:HEURE:VENT_MOY	-2.236e-09	4.645e-09	-0.481
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC:VENT_MOY	2.191e-05	6.402e-05	0.342
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY	-9.543e-10	8.406e-07	-0.001
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY	2.006e-09	2.080e-08	0.096
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY	-4.398e-10	1.321e-09	-0.333
##	Pr(> z )		
## (Intercept)	0.2754		
## TEMPERATURE	0.3056		
## ENSOLEILLEMENT	0.3366		
## HEURE	0.2341		
## PUBLIC	0.4982		
## VENT_MOY	0.0396 *		
## TEMPERATURE:ENSOLEILLEMENT	0.5767		
## TEMPERATURE:HEURE	0.2858		
## ENSOLEILLEMENT:HEURE	0.4311		
## TEMPERATURE:PUBLIC	0.3727		
## ENSOLEILLEMENT:PUBLIC	0.4600		
## HEURE:PUBLIC	0.5322		
## TEMPERATURE:VENT_MOY	0.0552 .		
## ENSOLEILLEMENT:VENT_MOY	0.9124		
## HEURE:VENT_MOY	0.0474 *		
## PUBLIC:VENT_MOY	0.8419		
## TEMPERATURE:ENSOLEILLEMENT:HEURE	0.5928		
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC	0.2827		
## TEMPERATURE:HEURE:PUBLIC	0.3522		
## ENSOLEILLEMENT:HEURE:PUBLIC	0.4707		
## TEMPERATURE:ENSOLEILLEMENT:VENT_MOY	0.7226		
## TEMPERATURE:HEURE:VENT_MOY	0.0624 .		
## ENSOLEILLEMENT:HEURE:VENT_MOY	0.7475		
## TEMPERATURE:PUBLIC:VENT_MOY	0.9736		
## ENSOLEILLEMENT:PUBLIC:VENT_MOY	0.8747		
## HEURE:PUBLIC:VENT_MOY	0.8488		
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC	0.2664		
## TEMPERATURE:ENSOLEILLEMENT:HEURE:VENT_MOY	0.6303		
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC:VENT_MOY	0.7322		
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY	0.9991		
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY	0.9232		
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY	0.7392		
## ---			
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1			

```
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 519.74 on 376 degrees of freedom
## Residual deviance: 461.68 on 345 degrees of freedom
## AIC: 525.68
##
## Number of Fisher Scoring iterations: 6
```

D'après notre modèle, VENT\_MOY a un effet significatif sur LATENCE\_BINAIRE. Il la diminue.

Maintenant que l'on a testé l'effet de l'environnement sur LATENCE\_BINAIRE, donc sur la présence ou non des FTN, nous allons étudier leur effet sur l'intensité de réponse.

On commence par étudier l'effet de la température sur chaque type de réponse.

#### a. Effet sur le nombre de strophes

```
##
## Call:
## MASS::glm.nb(formula = STROPHES_APRES ~ TEMPERATURE * ENSOLEILLEMENT *
## HEURE * PUBLIC * VENT_MOY, data = data_reponse, init.theta = 0.9620496045,
## link = log)
##
## Coefficients:
##
```

	Estimate	Std. Error	z value
(Intercept)	2.909e+00	4.751e+00	0.612
TEMPERATURE	-1.314e-01	3.927e-01	-0.334
ENSEOLEILLEMENT	1.681e-02	1.563e-02	1.076
HEURE	-7.043e-05	1.350e-04	-0.522
PUBLIC	-2.907e+00	2.359e+00	-1.232
VENT_MOY	-3.535e-01	7.156e-01	-0.494
TEMPERATURE:ENSEOLEILLEMENT	-1.069e-03	1.065e-03	-1.004
TEMPERATURE:HEURE	6.045e-06	9.825e-06	0.615
ENSEOLEILLEMENT:HEURE	-2.190e-07	3.356e-07	-0.653
TEMPERATURE:PUBLIC	2.305e-01	2.002e-01	1.151
ENSEOLEILLEMENT:PUBLIC	1.417e-03	4.603e-03	0.308
HEURE:PUBLIC	7.172e-05	5.205e-05	1.378
TEMPERATURE:VENT_MOY	2.475e-02	5.456e-02	0.454
ENSEOLEILLEMENT:VENT_MOY	-1.752e-03	2.068e-03	-0.847
HEURE:VENT_MOY	1.806e-05	1.811e-05	0.997
PUBLIC:VENT_MOY	1.156e-01	4.274e-01	0.270
TEMPERATURE:ENSEOLEILLEMENT:HEURE	1.236e-08	2.264e-08	0.546
TEMPERATURE:ENSEOLEILLEMENT:PUBLIC	-1.128e-04	3.476e-04	-0.325
TEMPERATURE:HEURE:PUBLIC	-5.279e-06	4.015e-06	-1.315
ENSEOLEILLEMENT:HEURE:PUBLIC	-6.344e-08	9.420e-08	-0.674
TEMPERATURE:ENSEOLEILLEMENT:VENT_MOY	1.233e-04	1.403e-04	0.879
TEMPERATURE:HEURE:VENT_MOY	-1.169e-06	1.256e-06	-0.931
ENSEOLEILLEMENT:HEURE:VENT_MOY	1.345e-08	4.383e-08	0.307
TEMPERATURE:PUBLIC:VENT_MOY	-1.244e-02	2.961e-02	-0.420
ENSEOLEILLEMENT:PUBLIC:VENT_MOY	6.306e-05	7.461e-04	0.085
HEURE:PUBLIC:VENT_MOY	-5.689e-06	9.667e-06	-0.589
TEMPERATURE:ENSEOLEILLEMENT:HEURE:PUBLIC	4.247e-09	6.791e-09	0.625
TEMPERATURE:ENSEOLEILLEMENT:HEURE:VENT_MOY	-1.035e-09	2.930e-09	-0.353
TEMPERATURE:ENSEOLEILLEMENT:PUBLIC:VENT_MOY	-3.716e-08	4.600e-05	-0.001
TEMPERATURE:HEURE:PUBLIC:VENT_MOY	4.024e-07	5.839e-07	0.689



```

## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY          5.245e-09  1.643e-08   0.319
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY -3.224e-10  9.148e-10  -0.352
##                                                    Pr(>|z|)
## (Intercept)                                0.540
## TEMPERATURE                                0.738
## ENSOLEILLEMENT                             0.282
## HEURE                                       0.602
## PUBLIC                                     0.218
## VENT_MOY                                  0.621
## TEMPERATURE:ENSOLEILLEMENT                0.315
## TEMPERATURE:HEURE                        0.538
## ENSOLEILLEMENT:HEURE                     0.514
## TEMPERATURE:PUBLIC                       0.250
## ENSOLEILLEMENT:PUBLIC                    0.758
## HEURE:PUBLIC                             0.168
## TEMPERATURE:VENT_MOY                     0.650
## ENSOLEILLEMENT:VENT_MOY                  0.397
## HEURE:VENT_MOY                           0.319
## PUBLIC:VENT_MOY                          0.787
## TEMPERATURE:ENSOLEILLEMENT:HEURE         0.585
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC        0.745
## TEMPERATURE:HEURE:PUBLIC                 0.189
## ENSOLEILLEMENT:HEURE:PUBLIC              0.501
## TEMPERATURE:ENSOLEILLEMENT:VENT_MOY     0.379
## TEMPERATURE:HEURE:VENT_MOY              0.352
## ENSOLEILLEMENT:HEURE:VENT_MOY            0.759
## TEMPERATURE:PUBLIC:VENT_MOY             0.674
## ENSOLEILLEMENT:PUBLIC:VENT_MOY           0.933
## HEURE:PUBLIC:VENT_MOY                    0.556
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC  0.532
## TEMPERATURE:ENSOLEILLEMENT:HEURE:VENT_MOY 0.724
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC:VENT_MOY 0.999
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY       0.491
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY    0.750
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY 0.724
##
## (Dispersion parameter for Negative Binomial(0.962) family taken to be 1)
##
##      Null deviance: 260.66  on 204  degrees of freedom
## Residual deviance: 234.64  on 173  degrees of freedom
## AIC: 1161.1
##
## Number of Fisher Scoring iterations: 1
##
##
##           Theta:  0.962
##          Std. Err.:  0.125
##
## 2 x log-likelihood: -1095.083

```

Ici, on a aucun effet détecté par notre modèle des variables environnementales sur le chant des FTN.

## b. Effet sur le nombre de cris

```
##
```

```
## Call:
## MASS::glm.nb(formula = CRIS ~ TEMPERATURE * ENSOLEILLEMENT *
##     HEURE * PUBLIC * VENT_MOY, data = data_reponse, init.theta = 0.2486821036,
##     link = log)
##
## Coefficients:
##
##               Estimate Std. Error z value
## (Intercept)    -9.944e+00  8.862e+00  -1.122
## TEMPERATURE     1.088e+00  7.433e-01   1.464
## ENSOLEILLEMENT   3.485e-02  3.114e-02   1.119
## HEURE           4.834e-04  2.544e-04   1.900
## PUBLIC          -1.624e+00  4.814e+00  -0.337
## VENT_MOY        1.542e+00  1.376e+00   1.121
## TEMPERATURE:ENSEOLEILLEMENT -2.373e-03  2.167e-03  -1.095
## TEMPERATURE:HEURE -4.002e-05  1.899e-05  -2.107
## ENSOLEILLEMENT:HEURE -9.305e-07  6.737e-07  -1.381
## TEMPERATURE:PUBLIC  4.680e-01  4.419e-01   1.059
## ENSOLEILLEMENT:PUBLIC -1.738e-02  1.279e-02  -1.359
## HEURE:PUBLIC       -6.513e-06  1.131e-04  -0.058
## TEMPERATURE:VENT_MOY -1.566e-01  1.082e-01  -1.447
## ENSOLEILLEMENT:VENT_MOY -4.264e-03  4.279e-03  -0.996
## HEURE:VENT_MOY     -5.251e-05  3.428e-05  -1.532
## PUBLIC:VENT_MOY    -4.960e-01  9.001e-01  -0.551
## TEMPERATURE:ENSEOLEILLEMENT:HEURE  6.882e-08  4.689e-08   1.468
## TEMPERATURE:ENSEOLEILLEMENT:PUBLIC  6.604e-04  1.050e-03   0.629
## TEMPERATURE:HEURE:PUBLIC -9.480e-06  1.017e-05  -0.933
## ENSOLEILLEMENT:HEURE:PUBLIC  4.126e-07  2.717e-07   1.519
## TEMPERATURE:ENSEOLEILLEMENT:VENT_MOY  3.147e-04  3.022e-04   1.041
## TEMPERATURE:HEURE:VENT_MOY  4.606e-06  2.446e-06   1.883
## ENSOLEILLEMENT:HEURE:VENT_MOY  1.105e-07  9.107e-08   1.213
## TEMPERATURE:PUBLIC:VENT_MOY -2.989e-02  7.412e-02  -0.403
## ENSOLEILLEMENT:PUBLIC:VENT_MOY  4.116e-03  2.318e-03   1.776
## HEURE:PUBLIC:VENT_MOY  2.524e-05  1.970e-05   1.282
## TEMPERATURE:ENSEOLEILLEMENT:HEURE:PUBLIC -1.266e-08  2.247e-08  -0.563
## TEMPERATURE:ENSEOLEILLEMENT:HEURE:VENT_MOY -8.151e-09  6.348e-09  -1.284
## TEMPERATURE:ENSEOLEILLEMENT:PUBLIC:VENT_MOY -2.136e-04  1.847e-04  -1.157
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY  1.110e-07  1.433e-06   0.078
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY -9.589e-08  4.754e-08  -2.017
## TEMPERATURE:ENSEOLEILLEMENT:HEURE:PUBLIC:VENT_MOY  4.242e-09  3.596e-09   1.179
##
##               Pr(>|z|)
## (Intercept)    0.2618
## TEMPERATURE    0.1433
## ENSOLEILLEMENT 0.2632
## HEURE          0.0574
## PUBLIC         0.7359
## VENT_MOY       0.2624
## TEMPERATURE:ENSEOLEILLEMENT 0.2735
## TEMPERATURE:HEURE 0.0351 *
## ENSOLEILLEMENT:HEURE 0.1672
## TEMPERATURE:PUBLIC 0.2895
## ENSOLEILLEMENT:PUBLIC 0.1741
## HEURE:PUBLIC       0.9541
## TEMPERATURE:VENT_MOY 0.1480
## ENSOLEILLEMENT:VENT_MOY 0.3191
```

```

## HEURE:VENT_MOY 0.1256
## PUBLIC:VENT_MOY 0.5816
## TEMPERATURE:ENSOLEILLEMENT:HEURE 0.1422
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC 0.5293
## TEMPERATURE:HEURE:PUBLIC 0.3510
## ENSOLEILLEMENT:HEURE:PUBLIC 0.1289
## TEMPERATURE:ENSOLEILLEMENT:VENT_MOY 0.2978
## TEMPERATURE:HEURE:VENT_MOY 0.0597 .
## ENSOLEILLEMENT:HEURE:VENT_MOY 0.2251
## TEMPERATURE:PUBLIC:VENT_MOY 0.6867
## ENSOLEILLEMENT:PUBLIC:VENT_MOY 0.0758 .
## HEURE:PUBLIC:VENT_MOY 0.2000
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC 0.5732
## TEMPERATURE:ENSOLEILLEMENT:HEURE:VENT_MOY 0.1991
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC:VENT_MOY 0.2474
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY 0.9382
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY 0.0437 *
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY 0.2382
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(0.2478) family taken to be 1)
##
## Null deviance: 255.30 on 204 degrees of freedom
## Residual deviance: 198.04 on 173 degrees of freedom
## AIC: 1319
##
## Number of Fisher Scoring iterations: 25
##
## Theta: 0.2487
## Std. Err.: 0.0281
## Warning while fitting theta: limite d'alternation atteinte
##
## 2 x log-likelihood: -1252.9590

```

Même chose pour le nombre de cris.

### c. Effet sur le nombre de survols

```

##
## Call:
## MASS::glm.nb(formula = SURVOLS ~ TEMPERATURE * ENSOLEILLEMENT *
## HEURE * PUBLIC * VENT_MOY, data = data_reponse, init.theta = 5.20384087,
## link = log)
##
## Coefficients:
## Estimate Std. Error z value
## (Intercept) -5.377e+00 4.816e+00 -1.117
## TEMPERATURE 7.856e-02 4.376e-01 0.180
## ENSOLEILLEMENT 4.172e-03 1.678e-02 0.249
## HEURE 2.494e-04 1.343e-04 1.856
## PUBLIC -2.146e+00 2.359e+00 -0.910
## VENT_MOY 7.326e-01 8.526e-01 0.859
## TEMPERATURE:ENSOLEILLEMENT 3.348e-04 1.182e-03 0.283

```

## TEMPERATURE:HEURE	-1.057e-05	1.086e-05	-0.974
## ENSOLEILLEMENT:HEURE	-3.545e-07	3.535e-07	-1.003
## TEMPERATURE:PUBLIC	2.794e-01	2.035e-01	1.373
## ENSOLEILLEMENT:PUBLIC	4.706e-03	6.227e-03	0.756
## HEURE:PUBLIC	2.306e-05	5.091e-05	0.453
## TEMPERATURE:VENT_MOY	-2.237e-02	6.563e-02	-0.341
## ENSOLEILLEMENT:VENT_MOY	-1.494e-03	2.471e-03	-0.604
## HEURE:VENT_MOY	-2.798e-05	2.291e-05	-1.221
## PUBLIC:VENT_MOY	2.162e-02	4.388e-01	0.049
## TEMPERATURE:ENSOLEILLEMENT:HEURE	1.061e-08	2.501e-08	0.424
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC	-6.746e-04	4.843e-04	-1.393
## TEMPERATURE:HEURE:PUBLIC	-4.464e-06	4.082e-06	-1.094
## ENSOLEILLEMENT:HEURE:PUBLIC	-5.413e-08	1.183e-07	-0.458
## TEMPERATURE:ENSOLEILLEMENT:VENT_MOY	5.387e-05	1.784e-04	0.302
## TEMPERATURE:HEURE:VENT_MOY	1.185e-06	1.585e-06	0.748
## ENSOLEILLEMENT:HEURE:VENT_MOY	5.575e-08	5.322e-08	1.048
## TEMPERATURE:PUBLIC:VENT_MOY	-2.588e-02	3.217e-02	-0.804
## ENSOLEILLEMENT:PUBLIC:VENT_MOY	-7.862e-05	8.696e-04	-0.090
## HEURE:PUBLIC:VENT_MOY	7.242e-06	1.005e-05	0.721
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC	1.078e-08	9.093e-09	1.186
## TEMPERATURE:ENSOLEILLEMENT:HEURE:VENT_MOY	-2.660e-09	3.794e-09	-0.701
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC:VENT_MOY	5.458e-05	5.951e-05	0.917
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY	1.445e-07	6.361e-07	0.227
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY	-1.036e-08	1.839e-08	-0.563
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY	-4.679e-10	1.149e-09	-0.407
##	Pr(> z )		
## (Intercept)	0.2641		
## TEMPERATURE	0.8575		
## ENSOLEILLEMENT	0.8036		
## HEURE	0.0634		
## PUBLIC	0.3630		
## VENT_MOY	0.3902		
## TEMPERATURE:ENSOLEILLEMENT	0.7769		
## TEMPERATURE:HEURE	0.3302		
## ENSOLEILLEMENT:HEURE	0.3160		
## TEMPERATURE:PUBLIC	0.1697		
## ENSOLEILLEMENT:PUBLIC	0.4498		
## HEURE:PUBLIC	0.6506		
## TEMPERATURE:VENT_MOY	0.7332		
## ENSOLEILLEMENT:VENT_MOY	0.5455		
## HEURE:VENT_MOY	0.2220		
## PUBLIC:VENT_MOY	0.9607		
## TEMPERATURE:ENSOLEILLEMENT:HEURE	0.6713		
## TEMPERATURE:ENSOLEILLEMENT:PUBLIC	0.1636		
## TEMPERATURE:HEURE:PUBLIC	0.2741		
## ENSOLEILLEMENT:HEURE:PUBLIC	0.6472		
## TEMPERATURE:ENSOLEILLEMENT:VENT_MOY	0.7626		
## TEMPERATURE:HEURE:VENT_MOY	0.4544		
## ENSOLEILLEMENT:HEURE:VENT_MOY	0.2949		
## TEMPERATURE:PUBLIC:VENT_MOY	0.4211		
## ENSOLEILLEMENT:PUBLIC:VENT_MOY	0.9280		
## HEURE:PUBLIC:VENT_MOY	0.4711		
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC	0.2358		
## TEMPERATURE:ENSOLEILLEMENT:HEURE:VENT_MOY	0.4833		

```

## TEMPERATURE:ENSOLEILLEMENT:PUBLIC:VENT_MOY      0.3590
## TEMPERATURE:HEURE:PUBLIC:VENT_MOY                0.8203
## ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY             0.5734
## TEMPERATURE:ENSOLEILLEMENT:HEURE:PUBLIC:VENT_MOY 0.6838
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(5.2038) family taken to be 1)
##
##      Null deviance: 263.92  on 204  degrees of freedom
## Residual deviance: 212.93  on 173  degrees of freedom
## AIC: 550.53
##
## Number of Fisher Scoring iterations: 1
##
##
##           Theta:  5.20
##          Std. Err.:  3.87
##
## 2 x log-likelihood: -484.531

```

Et même chose pour le nombre de survols.

Ainsi, nous pouvons dire que d'après nos modèles, nous n'avons pas d'effet des variables environnementales sur nos données.